Отчет по индивидуальному проекту №1 (4 вариант - зависимость между доходами населения и строительством новых квартир)

1. Исследовать наличие зависимости между двумя факторами. Если зависимость есть, то какая?
2. Построить модель для прогнозирования эндогенной переменной. Какие модели можно использовать для описания зависимости между факторами? Какие модели можно использовать для построения прогноза? Какую модель выбрать для построения прогноза?
3. Построить прогноз для Республики Карелия и сравнить с реальными данными. Оценить влияние независимого фактора на зависимый для Республики Карелия. Сделать экономические выводы.

Этап 1: Сбор данных

1	Год	Регион	mean_salary	flat_count
2	2000	Алтайский край	1224.2	4763
3	2000	Амурская область	1825.2	1676
4	2000	Архангельская обл...	2139.5	1042
5	2000	Ненецкий авт.округ	3426.3	181
6	2000	Астраханская область	1778.6	3364
7	2000	Белгородская область	1554.5	8700

1154 наблюдения по 91 региону за 13 лет.

Этап 2: Корреляционное поле, Линейная зависимость

Коэффициент корреляции: **0.1571**

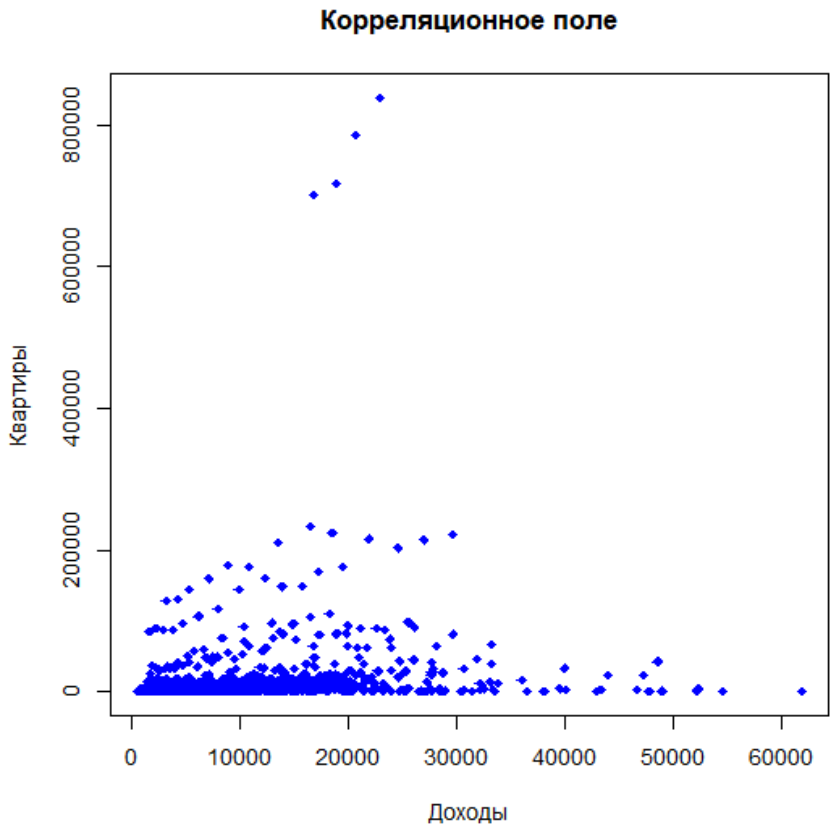
Корреляционное поле
Квартиры
0
200000
400000
600000
800000
0
10000
20000
30000
40000
50000
60000
Доходы

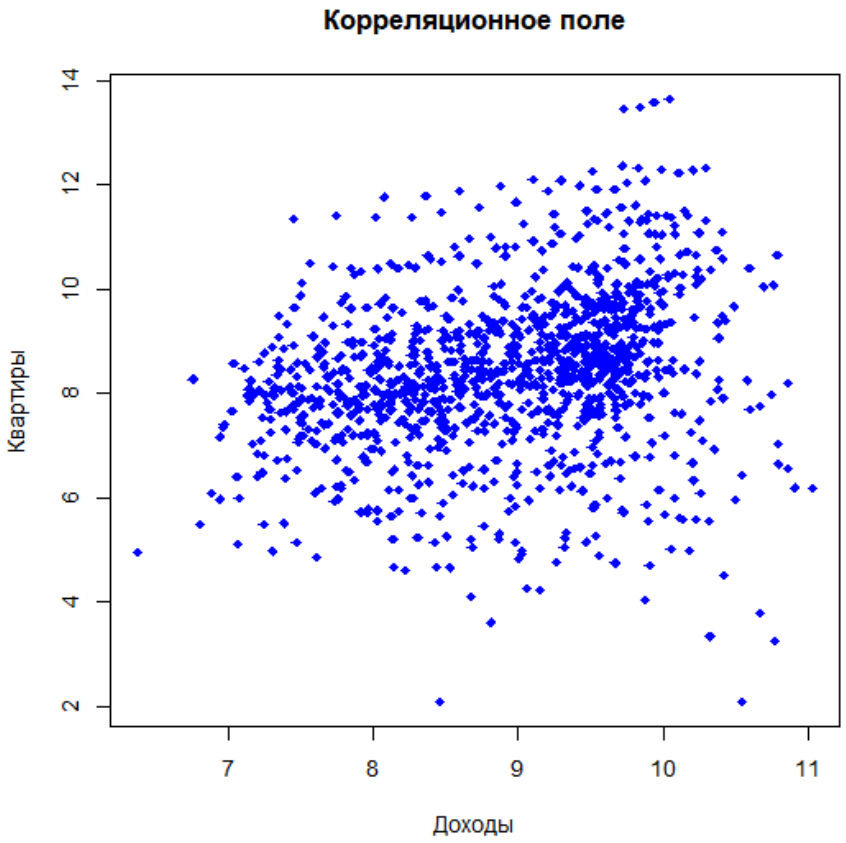
Корреляционное поле
Квартиры
2
4
6
8
10
12
14
7
8
9
10
11
Доходы

Этап 3: Выбор модели

	model	R2	Adj_R2	AIC
lin_lin	lin_lin	0.02467563	0.02383628	28548.020
log_log	log_log	0.05942663	0.05861719	4235.556
log_lin	log_lin	0.02814349	0.02730713	4273.640
lin_log	lin_log	0.02804959	0.02721314	28543.986

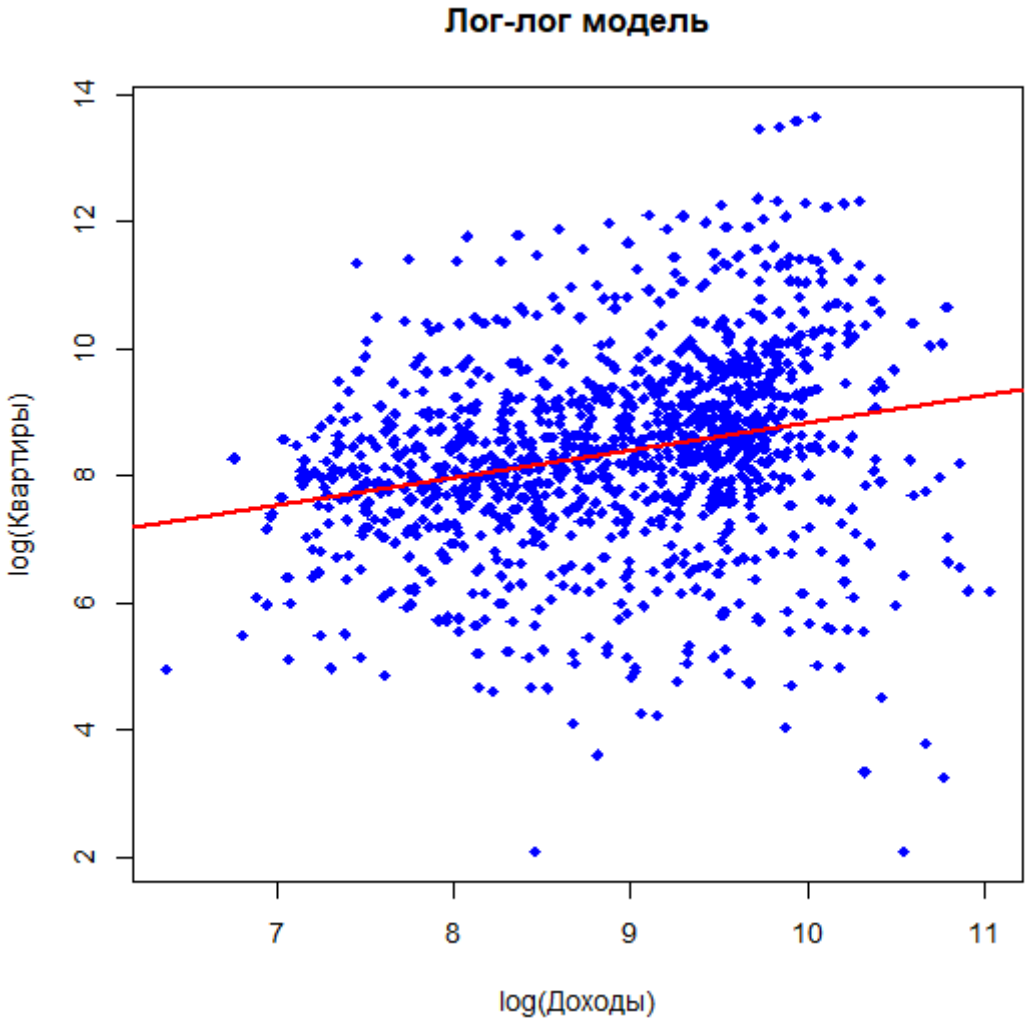

В общем виде выбрана log_log модель: ln(y) = ln(a0) + a1 * ln(x) + ε.

Рассмотрим модели с фиксированными эффектами для анализа панельных данных:

Сравнение панельных спецификаций

	Pooled	FE регионы	FE годы
log(mean_salary)	0.431***	0.441***	0.400***
	(0.050)	(0.018)	(0.106)
Num.Obs.	1164	1164	1164
R2	0.059	0.362	0.012
R2 Adj.	0.059	0.308	0.001
AIC	23732.4	20942.6	23726.7
BIC	23747.6	20952.7	23736.9
RMSE	1.49	0.45	1.49

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Наилучшая модель - фиксированные эффекты по регионам:

ln(y_i) = alpha_i + beta *ln(x_i) + ε_i, где beta - коэф. эластичности.

После учёта ненаблюдаемой фиксированной неоднородности регионов (модель с фиксированными эффектами по регионам) наблюдается статистически значимая положительная связь между среднедушевыми денежными доходами и объёмом построенного жилья. Эластичность составляет примерно **0.44**: 10-процентный рост реальных доходов населения региона (относительно его долгосрочного уровня) ассоциируется с ростом количества построенных квартир примерно на 4.4%.

Pooled модель сильно недооценивает эту связь из-за игнорирования межрегиональных различий в институциональных, географических и демографических факторах.

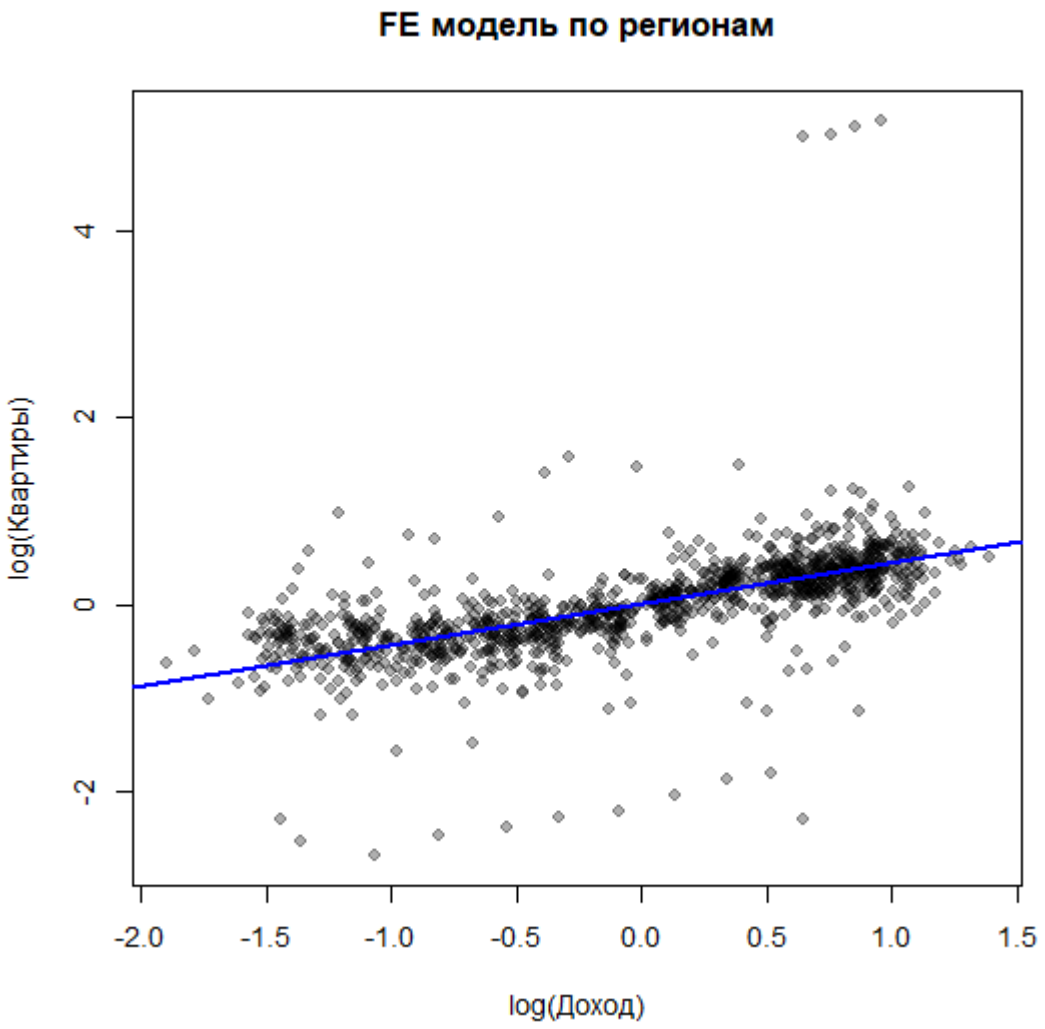

График отражает наблюдение, очищенные от региональных различий, координаты точек определены отклонением текущего наблюдения от среднего значения за все годы именно по своему региону, а прямая (y = 0.44x) демонстрирует общую тенденцию зависимости строительства от доходов.

Этап 4: Верификация модели (Значимость, остатки, точность прогноза)

Значимость регрессии проверена с помощью F-теста Фишера. Значение статистики F составило 608 при 1072 степенях свободы, p-value < 2.2e-16. Таким образом, нулевая гипотеза о незначимости модели отвергается на любом разумном уровне значимости. Модель с фиксированными эффектами по регионам статистически значима. Суть этой визуализации в том, что каждая точка перестает сравниваться с общей массой, а демонстрирует зависимость эндогенной и экзогенной переменных только в рамках своего региона.

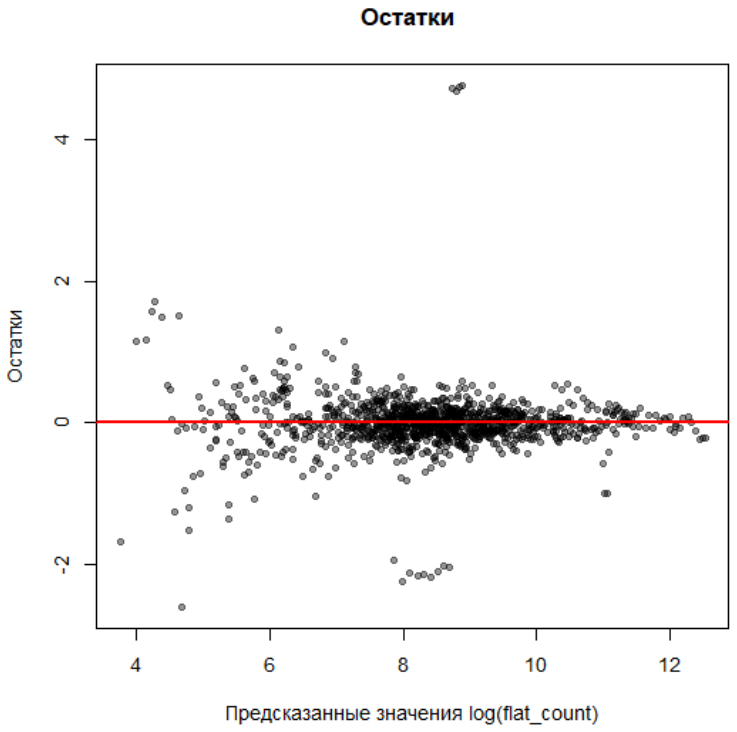
Остатки
Остатки
4
2
0
-2
4
6
8
10
12
Предсказанные значения log(flat_count)

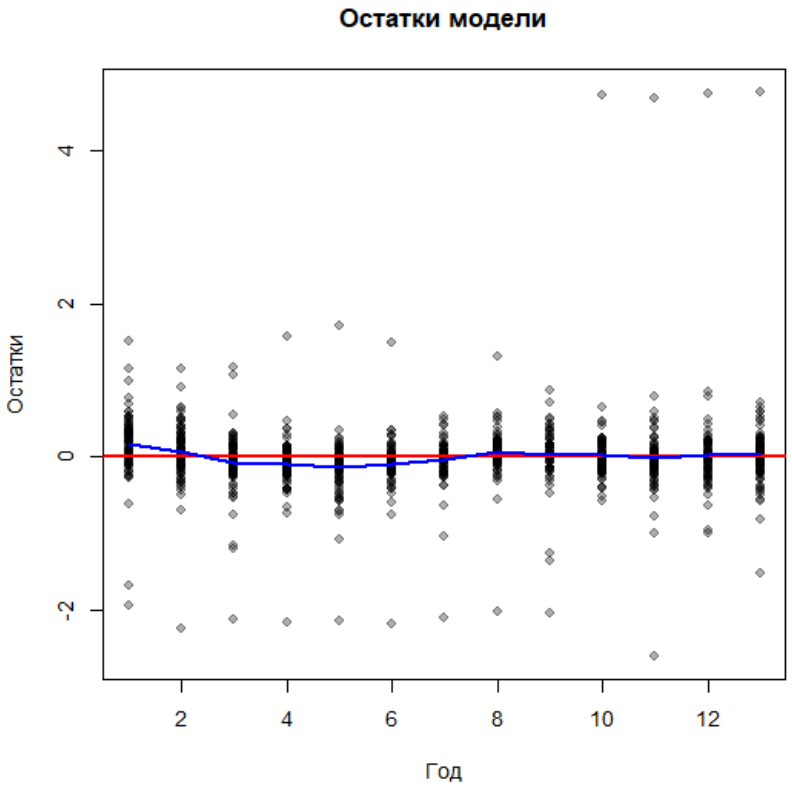
Остатки модели
Остатки
4
2
0
-2
2
4
6
8
10
12
Год

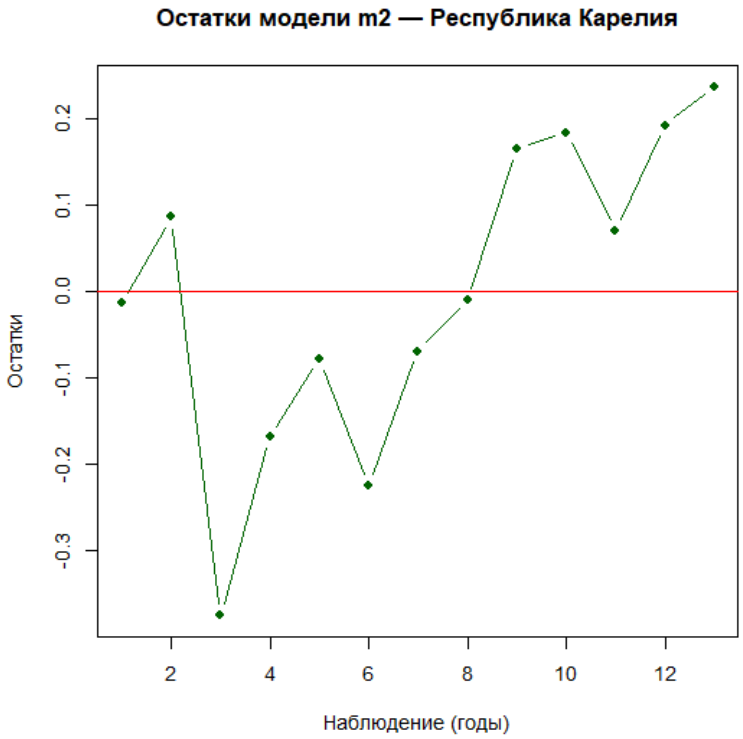

Графики остатков демонстрируют, что математическое ожидание остатков близко к нулю и не зависит систематически от уровня предсказанных значений или времени. Наблюдается умеренная гетероскедастичность (небольшое увеличение дисперсии в крайних значениях), однако она не носит ярко выраженного характера. Отдельные выбросы присутствуют, что типично для панельных данных по регионам с очень разным масштабом жилищного строительства. В целом диагностика остатков не выявляет грубых нарушений предположений модели, позволяя считать оценки состоятельными и интерпретируемыми.

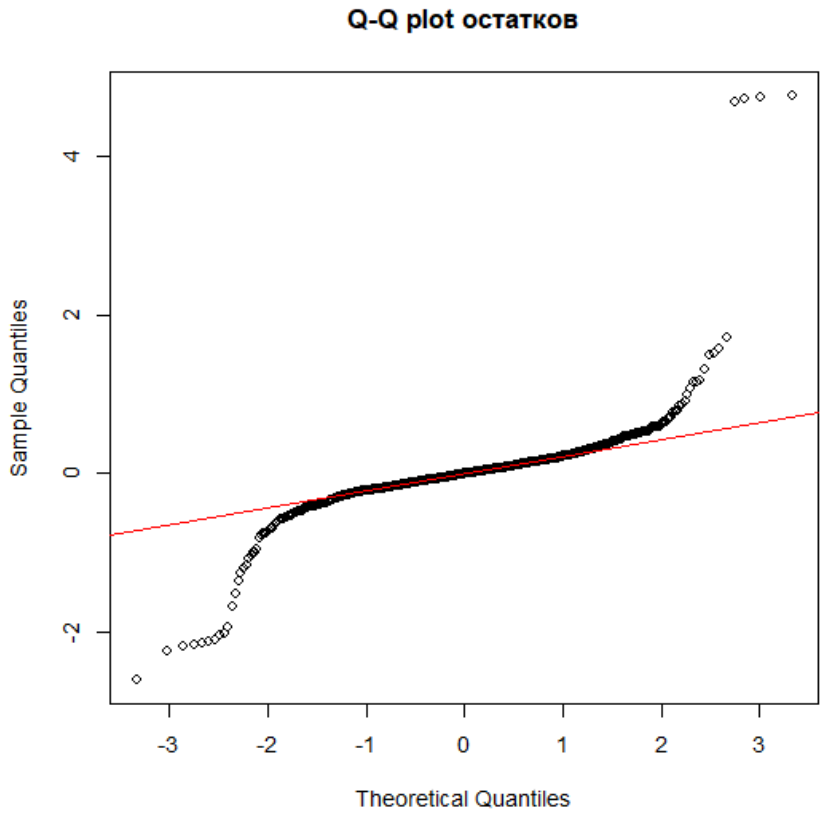

Средняя абсолютная процентная ошибка (MAPE) модели с фиксированными эффектами по регионам составляет 27.64328%, что указывает на приемлемую точность предсказаний количества построенных квартир на уровне отдельных регионов и лет, но в то же время подтверждает гипотезу о том, что в данной задаче наилучшим образом себя покажет множественная регрессия.

Этап 5: Прогноз для Респ. Карелия.

2008 год:

Фактический доход: 12834
Фактические квартиры: 2122
Прогноз: 1798
Абсолютная ошибка: -324
Относительная ошибка: -15.28 %

Выводы

Регионы очень разные по абсолютному уровню строительства
Москва и МО, Краснодарский край, Татарстан, Ленинградская область — строят в десятки раз больше жилья на душу, чем Чукотка, Магадан, Еврейская АО, многие республики Северного Кавказа и т.д. Различия в уровне объясняются не доходами, а институтами, доступностью земли, миграцией, федеральной поддержкой, климатом, размером региона и т.д.

Доходы тоже сильно различаются между регионами, но эти различия не полностью объясняют разницу в строительстве → остается огромный фиксированный эффект региона.

Главный итог - модель нелинейной (логарифмической) зависимости с фикс. эффектами имеет право на жизнь, но требует доработок и покажет себя лучше при использовании множественной регрессии, так как уровень строительства зависит от множества факторов, одним из которых, но не основным, является доход населения.
Полученная на данном этапе модель, уже показывает себя неплохо.