Отчет по индивидуальному проекту №1 (4 вариант - зависимость между доходами населения и строительством новых квартир)

1. Исследовать наличие зависимости между двумя факторами. Если зависимость есть, то какая?
2. Построить модель для прогнозирования эндогенной переменной. Какие модели можно использовать для описания зависимости между факторами? Какие модели можно использовать для построения прогноза? Какую модель выбрать для построения прогноза?
3. Построить прогноз для Республики Карелия и сравнить с реальными данными. Оценить влияние независимого фактора на зависимый для Республики Карелия. Сделать экономические выводы.

Этап 1: Сбор данных

1	Год	Регион	mean_salary	flat_count
2	2000	Алтайский край	1224.2	4763
3	2000	Амурская область	1825.2	1676
4	2000	Архангельская обл...	2139.5	1042
5	2000	Ненецкий авт.округ	3426.3	181
6	2000	Астраханская область	1778.6	3364
7	2000	Белгородская область	1554.5	8700

Проанализировав две таблицы, вручную были удалены строки-дубли, путем их объединения, например, регион имел две записи в таблице, в одной из которых были записи за 2000-2007, а в другой - за 2008-2012.

Также в ходе анализа таблиц был выявлен явный дефект, который нарушил бы итоговую выборку - столбец “Российская Федерация”, он был удален.

Нулевые значения были отвергнуты перед анализом. Итоговая выборка получилось путем объединения двух таблиц с данными, в неё попали только те наблюдения, который имели информацию в обоих таблицах, то есть ненулевые значения в обеих таблицах.
В результате в итоговую выборку для анализа попало 1164 уникальных наблюдения по 91 региону за 13 лет (2000-2012).

BF
Российская Федерация
373
317
396
427
477
515
609
722
768
701 857
716 930
785 561
838 029

Этап 2: Корреляционное поле, Линейная зависимость

```
> cor.test(final_df_sorted$mean_salary, final_df_sorted$flat_count, conf.level = 0.9)

        Pearson's product-moment correlation

data:  final_df_sorted$mean_salary and final_df_sorted$flat_count
t = 6.3516, df = 1162, p-value = 3.052e-10
alternative hypothesis: true correlation is not equal to 0
90 percent confidence interval:
 0.1361422 0.2293851
sample estimates:
      cor
0.1831756
```

Коэффициент корреляции составил **0.1831756**, корреляция значима на уровне доверия 90%. При этом такой низкий коэффициент корреляции говорит о совсем слабой линейной связи, а вероятнее всего об её отсутствии.

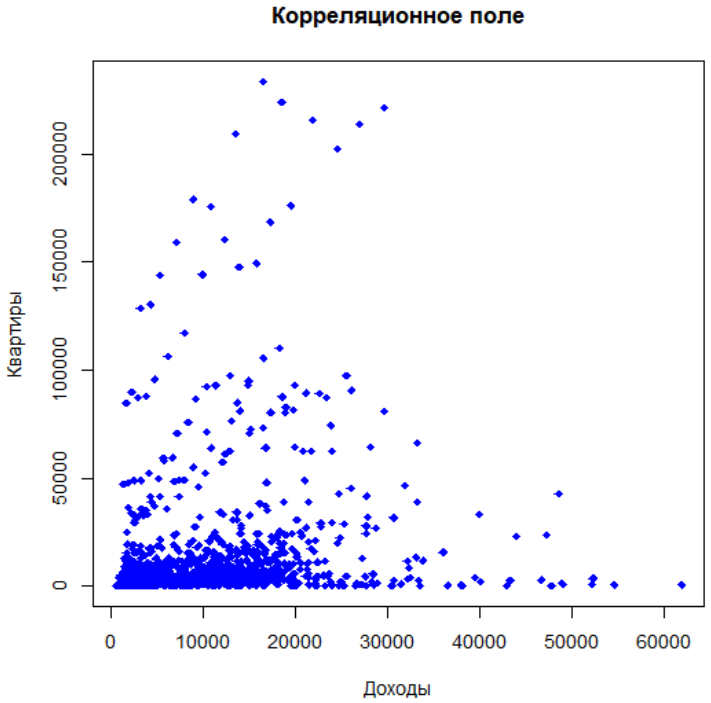

Построив корреляционное поле, стало понятно, что гипотеза об отсутствии линейной связи верна, облако напоминает логарифм. График ниже демонстрирует корреляционное поле в логарифмических координатах, по нему видно, что гипотеза о логарифмической оправдана. Выбросов не обнаружено.

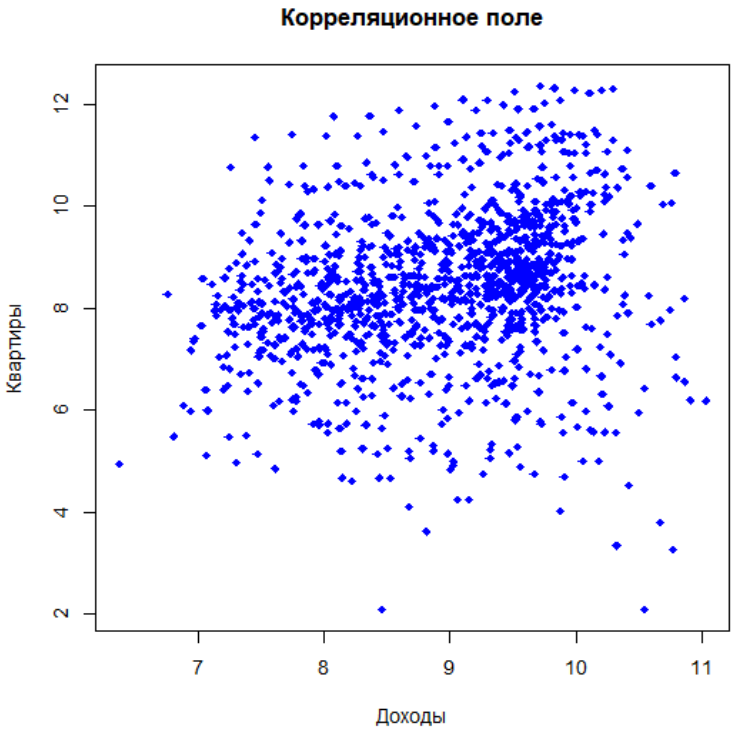

Отдельно было рассмотрено соотношение строительства и доходов в среднем по стране за 2000-2012 годы. Видно, как два графика идут наверх одновременно и примерно с одной скоростью, что явно говорит нам о том, что зависимость между доходами и строительством есть.
Доходы населения растут постепенно и без скачков, скорость роста примерно одинаковая в каждый год.
Строительство квартир напротив, имеет плавно растущий график в 2000-2005, затем показывает мощный рост в 2005-2008 годах и резкий обвал в 2008-2010 годах, потом возвращаясь к росту в темпе 2004-2005 годов.

Экономически это объясняется тем, что в 2005-2008 годах в России были низкие кредитные ставки, провоцирующие людей на доступную ипотеку, также в страну активно шёл иностранный капитал, население богатело, были большие цены на нефть и ситуация располагала в быстрому росту экономики, что отражалась на строительном секторе.

Строительство квартир сильно зависит от необходимости в них, то есть от населенности региона и роста его населения (естественного + миграции), отсюда точно можно сделать вывод о том, что описать всю страну одной моделью будет неграмотно, каждый регион имеет свои тенденции, это демонстрируется на графике ниже.

Корреляционное поле: Доходы и построенные квартиры

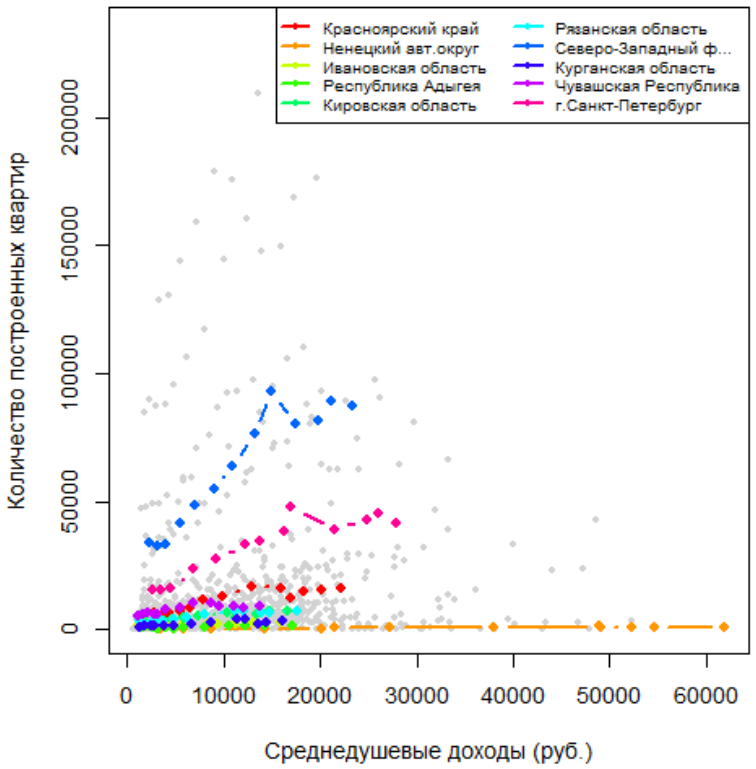

Корреляционное поле: Доходы и построенные квартиры

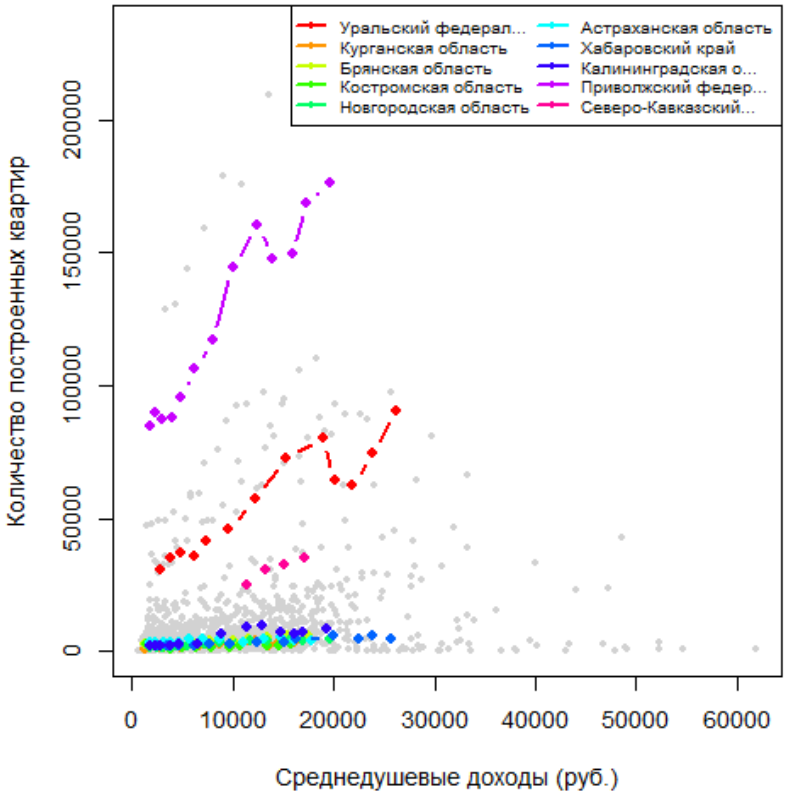

Наглядно видно, что в населенном Приволжье строят очень много, Урал и Чувашия имеют средние показатели по выборке, а в Ненецком АО даже при огромных зарплатах строительство не поднимается выше отметки в 1000 квартир в год, кроме 2008, в остальные годы от 100 до 700 квартир.

Этап 3: Выбор модели

```
> print(comparison)
          model         R2     Adj_R2       AIC
lin_lin lin_lin 0.03355331 0.03272160 27106.095
log_log log_log 0.05173251 0.05091645  4220.654
log_lin log_lin 0.02201251 0.02117087  4256.575
lin_log lin_log 0.04221546 0.04139121 27095.615
```

Дабы не упустить возможную хорошую связь, были протестированы 4 комбинации линейной и логарифмической зависимостей. Наилучшим образом по тесту Акаике и коэффициенту детерминации себя показывает модель log_log вида ln(y) = ln(a0) + a1 * ln(x) + ε.

```
> coef(reg_log)
     (Intercept) log(mean_salary)
        4.859851         0.397708
```

Итоговый вид логарифмической модели:

- log(flat_count) = 4.859851 + 0.397708 × log(mean_salary)
- flat_count = e^(4.859851) × mean_salary^(0.397708) - в виде степенной

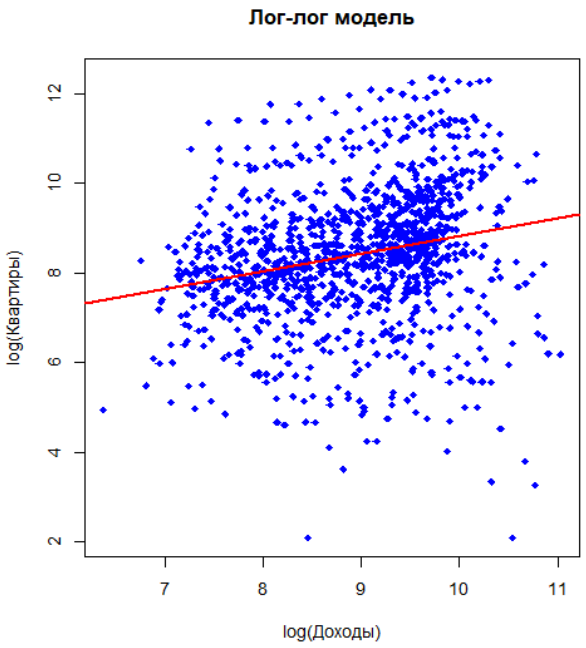

В ходе исследования было решено рассмотреть модели с фиксированными эффектами, т.к. такой подход идеально подойдет к задаче о строительстве в разных регионах, которые отличаются географически, климатически, демографически и т.д.

Сравнение панельных спецификаций

	Pooled	FE регионы	FE годы
log(mean_salary)	0.398***	0.406***	0.376***
	(0.050)	(0.012)	(0.106)
Num.Obs.	1164	1164	1164
R2	0.052	0.519	0.011
R2 Adj.	0.051	0.478	-0.000
AIC	23785.2	20077.7	23779.9
BIC	23800.4	20087.8	23790.0
RMSE	1.48	0.30	1.48

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Наилучшая модель - **фиксированные эффекты по регионам**:

ln(y_i) = α_i + beta *ln(x_i) + ε_i, где beta - общий коэф. эластичности, а α_i - уникальный эффект для каждого региона.

log(flat_count) = α_i + 0.4064 × log(mean_salary)

Эластичность составляет **0.406**: 10-процентный рост реальных доходов населения региона ассоциируется с ростом количества построенных квартир примерно на 4%.

Коэффициент β = 0.406 в FE-модели очень близок к коэффициенту из Pooled-регрессии (0.398). Это говорит о том, что связь между доходами и строительством устойчива даже после учёта региональных особенностей.

Суть данной модели в нахождении индивидуальной особенности каждого региона путем нахождения его уникального коэффициента α. Если у региона большой положительный α_i, это значит, что при том же уровне доходов, как и в других регионах, здесь строится систематически больше квартир.

Например, наименьший α у Чукотки (0.37), а наибольший у ЦФО (8.3), это говорит нам о том, что при в условиях одинаковой средней зарплаты в этих двух регионах разница в кол-ве построенных квартир была бы в 22 раза.

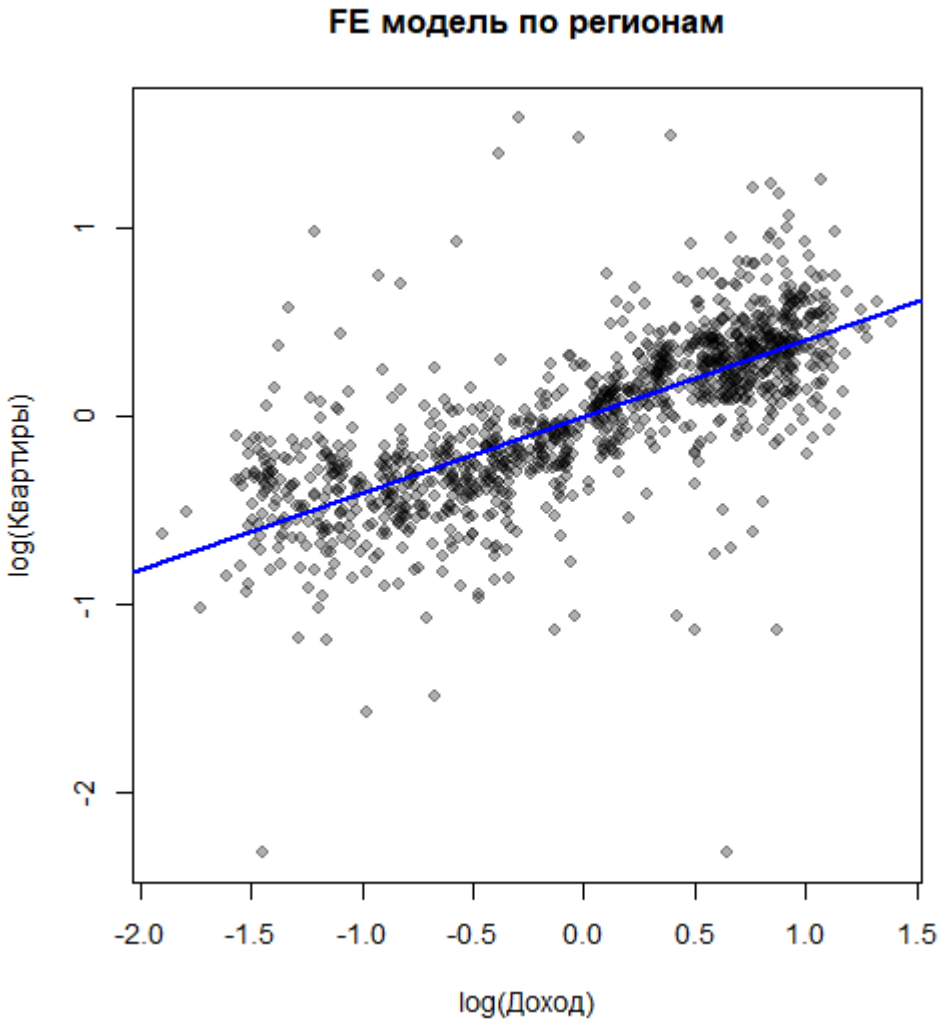

График отражает наблюдение, очищенные от региональных различий, координаты точек определены отклонением текущего наблюдения от среднего значения за все годы именно по своему региону, а прямая (y = 0.406x) демонстрирует общую тенденцию зависимости строительства от доходов. Суть данной трансформации в том, чтобы вычесть среднее по своему региону из каждого наблюдения, это будет демонстрировать относительные изменения строительства, вызванные повышением дохода, а не абсолютные.

Этот график доказывает, что связь между доходами и строительством существует не только между регионами (богатые регионы строят больше), но и внутри регионов во времени (когда регион становится богаче, он начинает строить больше).

С помощью Excel был вычислен средний фикс. эффект для регионов - **2.5198**. Это можно интерпретировать в дальнейшем при анализе каждого конкретного региона: если его α ниже, чем 2.5198, то регион строит меньше других при таком же уровне дохода.

Этап 4: Верификация модели (Значимость, остатки, точность прогноза)

Значимость регрессии проверена с помощью F-теста Фишера. Значение статистики F составило 1155 при 1072 степенях свободы, p-value < 2.2e-16. Таким образом, нулевая гипотеза о незначимости модели отвергается на любом разумном уровне значимости. Модель с фиксированными эффектами по регионам статистически значима.

```
> summary(m2)
Oneway (individual) effect Within Model

Call:
plm(formula = log(flat_count) ~ log(mean_salary), data = pdata,
    effect = "individual", model = "within")

Unbalanced Panel: n = 91, T = 3-13, N = 1164

Residuals:
     Min.   1st Qu.    Median   3rd Qu.      Max.
-2.578298 -0.142655  0.006261  0.144703  1.701917

Coefficients:
                Estimate Std. Error t-value  Pr(>|t|)
log(mean_salary) 0.406446   0.011956  33.995 < 2.2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    219.33
Residual Sum of Squares: 105.55
R-Squared:      0.51877
Adj. R-Squared: 0.47792
F-statistic: 1155.64 on 1 and 1072 DF, p-value: < 2.22e-16
```

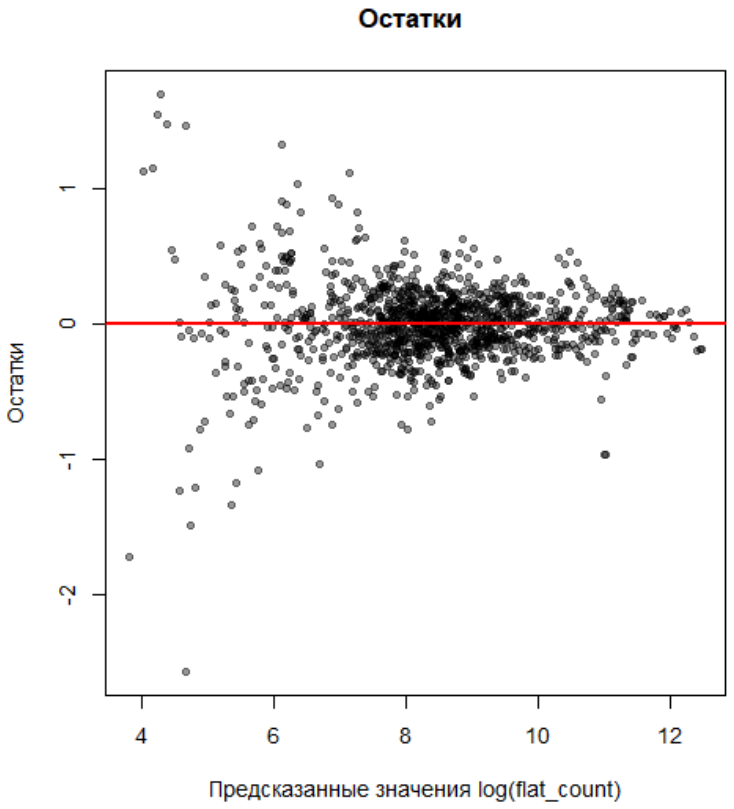
Остатки
Остатки
1
0
-1
-2
4
6
8
10
12
Предсказанные значения log(flat_count)

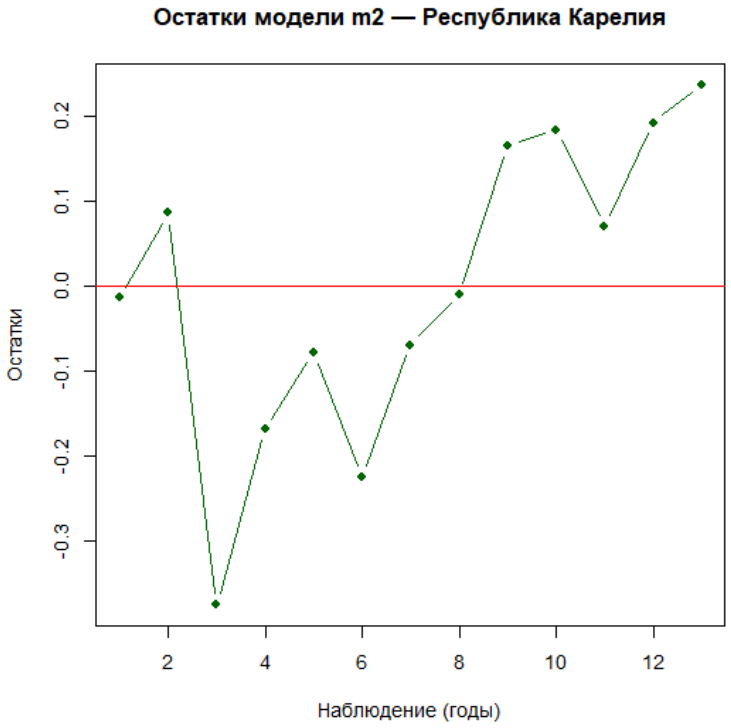
Остатки модели m2 — Республика Карелия
Остатки
0.2
0.1
0.0
-0.1
-0.2
-0.3
2
4
6
8
10
12
Наблюдение (годы)

Графики остатков демонстрируют, что математическое ожидание остатков близко к нулю (**1.07757400868876e-16**) и не зависит систематически от уровня предсказанных значений или времени. Наблюдается умеренная гетероскедастичность (небольшое увеличение дисперсии в крайних значениях), однако она не носит ярко выраженного характера. В целом диагностика остатков не выявляет грубых нарушений предположений модели, позволяя считать оценки состоятельными.

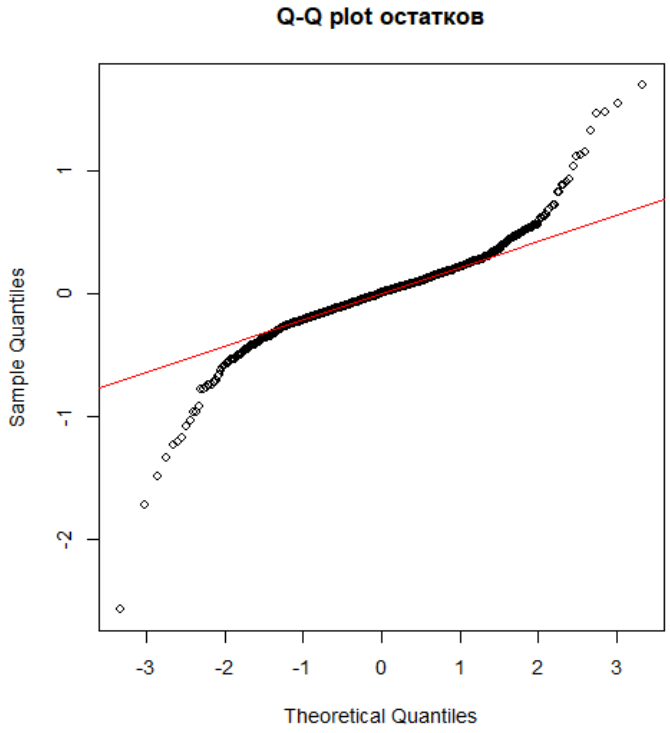

Средняя абсолютная процентная ошибка (MAPE) модели с фиксированными эффектами по регионам составляет 21.97748%, что указывает на приемлемую точность предсказаний количества построенных квартир на уровне отдельных регионов и лет, но в то же время подтверждает гипотезу о том, что в данной задаче наилучшим образом себя покажет множественная регрессия.

```
> mape
[1] 21.97748
```

Этап 5: Прогноз для Респ. Карелия.

2010 год:

```
> cat("Фактический доход:", round(actual_salary, 0), "\n")
Фактический доход: 16046
> cat("Фактические квартиры:", actual_flats, "\n")
Фактические квартиры: 2129
> cat("Прогноз m2:", round(pred_flats_m2, 0), "\n")
Прогноз m2: 1937
> cat("Абсолютная ошибка:", round(pred_flats_m2 - actual_flats, 0), "\n")
Абсолютная ошибка: -192
> cat("Относительная ошибка:", round((pred_flats_m2 - actual_flats)/actual_flats * 100, 2), "%\n")
Относительная ошибка: -9.01 %
>
```

Модель для Респ. Карелия: log(flat_count) = 3.6333 + 0.4064 × log(mean_salary)

Также был сделан прогноз для года, которого не было в выборке: были найдены данные о зарплате в Карелии за 2024 год - 74.210 рублей, а также данные о строительстве - 1933 за первое полугодие (предположим, что во втором построили примерно столько же), тогда за год построено около 3850 квартир.

log(flat_count) = 3.6333 + 0.4064 × log(74210) ≈ **3600**

Как итог, модель показала отличные результаты для республики Карелия: ошибка 9% для 2010 года и 6.5% для 2024 года.

Выводы

Регионы очень разные по абсолютному уровню строительства:
Москва и МО, Краснодарский край, Татарстан, Ленинградская область — строят в десятки раз больше жилья на душу, чем Чукотка, Магадан, Еврейская АО, многие республики Северного Кавказа и т.д. Различия в уровне объясняются не доходами, а институтами, доступностью земли, миграцией, федеральной поддержкой, климатом, размером региона и т.д.

Доходы тоже сильно различаются между регионами, но эти различия не полностью объясняют разницу в строительстве, остается огромный фиксированный эффект региона.
Когда были убраны все эти региональные особенности (они как раз и есть тот самый "фиксированный эффект"), оказалось, что внутри каждого отдельного региона доходы всё-таки влияют на строительство, но влияние это не самое сильное — коэффициент 0.4 говорит о том, что строительство реагирует на рост доходов, но не так бурно.

Главный итог - модель нелинейной (логарифмической) зависимости с фикс. эффектами имеет право на жизнь, но требует доработок и покажет себя лучше при использовании множественной регрессии, так как уровень строительства зависит от множества факторов, одним из которых, но не основным, является доход населения.
Полученная на данном этапе модель, уже показывает себя неплохо.

В результате исследования была создана общая модель с фиксированными эффектами, её коэффициенты записаны в отдельном csv файле, там же приведена конкретная модель для каждого региона.

Источники

1. Объем строительства в Карелии за первое полугодие 2024 года // РБК Карелия. — 21 августа 2024. — URL: https://karelia.rbc.ru/karelia/21/08/2024/66c5b4d49a794719bde00d47