Отчет по индивидуальному проекту №2 (4 вариант - зависимость между доходами, населением, географией региона и строительством новых квартир в регионе)

1. Исследовать зависимость между несколькими факторами (население, доход, геогр. широта, расстояние до Москвы, ФО). Если зависимость есть, то какая?
2. Построить модель для прогнозирования эндогенной переменной. Какие модели можно использовать для описания зависимости между факторами? Какие модели можно использовать для построения прогноза? Какую модель выбрать для построения прогноза?
3. Построить прогноз для Республики Карелия и сравнить с реальными данными. Оценить влияние независимого фактора на зависимый для Республики Карелия. Сделать экономические выводы.

ЭТАП 1: СБОР ДАННЫХ

После сбора данных для первого исследования (доход — строительство) был сформирован документ, содержащий 1164 записи о наблюдениях по регионам РФ, каждая запись включает в себя средний доход и кол-во построенных квартир в этот год в этом регионе.
Всего в документе представлены данные о 91 регионе за 13 лет, содержимое провалидировано: нулевые строки и дубли данных отсутствуют, выброс (РФ) удален.

Полученные данные необходимо было дополнить информацией о географии регионов и их население.
Статические данные, не меняющиеся во времени (Федеральный округ, широта, расстояние до Москвы) были вручную заполнены для каждого региона и продублированы для всех записей об этом регионе в итоговой .csv таблице. При этом были сделаны два допущения:

1. Северо-Кавказский ФО появился позже остальных — в 2010 году, регионы, вошедшие в него, до этого состояли в ЮФО, но для простоты анализа было принято решение отнести их к СКФО на всём корпусе данных, т.е. для всех записей об этих регионах.
2. Географическая широта и расстояние до Москвы считались от областного (окружного) центра, например, г. Архангельск для Архангельской области.

Ситуация с данными о населении куда сложнее, их пришлось собирать в несколько этапов, тщательно валидируя полученный на каждом из этапов результат:

1. DemoScope: 2000 и 2005 годы.
2. Росстат: 2001, 2006–2012 годы.
3. Statbase: 2002-2004 годы.

Весь этап сбора информации был автоматизирован с помощью написания скрипта на python, который выполнял парсинг онлайн-таблиц с данными о населении регионов РФ и дополнял итоговый файл.

	Год	Регион	mean_salary	flat_count	latitude	distance_to_moscow_km	Population	district
1	2000	Алтайский край	1224.2	4763	53.3548	3600	2652.0	СФО
2	2000	Амурская область	1825.2	1676	50.2907	6500	936.0	ДВФО
3	2000	Архангельская обл...	2139.5	1042	64.5393	1200	1390.0	СЗФО
4	2000	Ненецкий авт.округ	3426.3	181	67.6383	1500	41.0	СЗФО
5	2000	Астраханская область	1778.6	3364	46.3497	1400	1012.0	ЮФО
6	2000	Белгородская область	1554.5	8700	50.5978	700	1502.0	ЦФО
7	2000	Брянская область	1312.1	2876	53.2521	380	1423.0	ЦФО

Рис.1. Итоговый .csv файл

Сложности добавляло разное написание регионов в разных источниках, пришлось составлять 3 маппинга, каждый из которых состоял из 91 пары (регион в источнике — региона в исходной таблице): region_map_statbase, region_map_rosstat, region_map_demoscope.

```
region_map_rosstat = {
    'Центральный федеральный округ': 'Центральный федер...',
    'Северо-Западный федеральный округ': 'Северо-Западный ф...',
    'Приволжский федеральный округ': 'Приволжский федер...',
    'Уральский федеральный округ': 'Уральский федерал...',
    'Сибирский федеральный округ': 'Сибирский федерал...',
    'Дальневосточный федеральный округ': 'Дальневосточный ф...',
    'Южный федеральный округ': 'Южный федеральный...',
    'Северо-Кавказский федеральный округ': 'Северо-Кавказский...',

    # Основные субъекты
    'Алтайский край': 'Алтайский край',
    'Амурская область': 'Амурская область',
```

Рис.2. Пример маппинга

ЭТАП 2: ВВЕДЕНИЕ И СТАРТОВЫЙ АНАЛИЗ

В ходе исследования №1 была выявлена логарифмическая зависимость между доходами населения и строительством новых квартир. Аналогичная зависимость между этими факторами будет и в модели множественной регрессии.

Влияние масштаба населения на жилищное строительство носит нелинейный характер: удвоение населения не приводит к удвоению объема строительства из-за эффекта насыщения и институциональных ограничений. Логарифмическая зависимость позволяет интерпретировать коэффициент как эластичность — процентное изменение количества построенных квартир при изменении населения на 1%. Это экономически осмысленный коэффициент, пригодный для сравнения территорий разного масштаба.

Приступив к анализу, было замечено, что одна из экзогенных переменных качественная — Федеральный округ. Ввиду наличия восьми градаций данной переменной и отсутствия у нее определяющего влияния на предмет исследования (поскольку внутри одного округа возможны различные тренды строительства), использование единой регрессионной модели с фиктивными переменными представляется неоправданным.

Оптимальным решением в сложившихся условиях является разделение выборки:

1. Общая окружная модель (в выборку войдут только записи об округах). Она послужит инструментом для анализа общероссийской динамики соотношения доходов и строительства, а также для межокружных сравнений.
2. Частные окружные модели (выборка - регионы одного округа). Их построение позволяет изучить внутреннюю динамику и провести сравнительный анализ регионов в границах каждого федерального округа.

Простейшая модель с фиктивными переменными всё же была проверена, показав хороший R^2 (0.8462). Несмотря на кажущуюся высокую объясняющую способность, ее практическая применимость оказалась ограниченной из-за относительной ошибки прогноза около 70% (RSE = 0.5275 в логарифмическом масштабе). Это означает, что при прогнозировании модель в среднем ошибается более чем в два раза, что делает ее непригодной для составления прогноза для регионов.

$$log(Y) \sim log(salary) + log(Population) + latitude + distance + factor(district)$$

Такой эксперимент только подтвердил начальное предположение о неоправданности такого подхода к анализу.

Этап 3: Анализ связи между регрессорами

Интуитивно ожидаемо, что ключевым фактором, определяющим абсолютные масштабы строительства в регионе, выступает численность населения, тогда как уровень доходов играет роль драйвера относительного роста. Представленный график иллюстрирует динамику трёх показателей в период 2000–2012 годов: средней заработной платы (усреднённой по регионам за год), ввода новых квартир (суммарно по всем регионам) и общей численности населения страны. Все ряды нормализованы относительно первого года выборки, что позволяет сопоставлять траектории изменений, а не абсолютные значения.

В общенациональном масштабе динамика населения не выступает значимым фактором, определяющим объёмы строительства: на протяжении всего рассматриваемого периода население России оставалось практически неизменным (145 млн человек в 2000 г. против 143 млн в 2012 г.), тогда как ввод жилья демонстрировал устойчивый положительный тренд. Траектория средней заработной платы схожа с динамикой строительства: оба показателя характеризуются замедлением в 2007–2009 гг. и последующим восстановлением, при этом доходы росли более высокими темпами. Такое соотношение подтверждает гипотезу о том, что именно доходы населения выступают основным драйвером роста строительной активности.

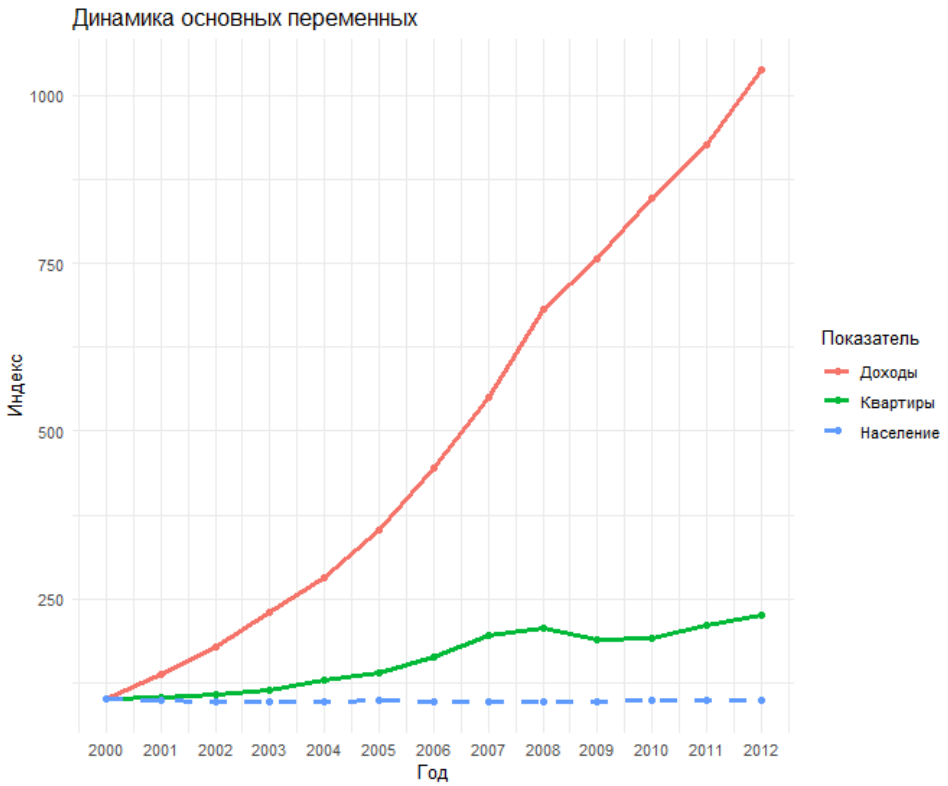

Рис.3. Динамика основных переменных

В наборе экзогенных переменных есть пара, которая точно имеет высокую корреляцию: широта и расстояние до Москвы, в дальнейшем это подтвердится при анализе регрессии и корреляционной матрицы, а сейчас узнаем тип их связи.
На представленном графике каждая точка соответствует отдельному региону, а аппроксимирующая кривая, имеющая параболическую форму, позволяет выявить ряд важных географических особенностей России:

1. Подавляющее большинство регионов страны расположено в интервале между 50° и 70° северной широты. При этом наблюдается выраженная асимметрия: при движении на юг от широты Москвы (55° с.ш.) количество регионов заметно выше, чем при движении на север. Данное распределение объясняется тем, что северные территории представлены преимущественно крупными по площади, но немногочисленными по количеству субъектами (Ямало-Ненецкий автономный округ, Красноярский край, Качматчка). В то время как в южной части страны сосредоточено значительно большее число регионов с меньшей площадью, что и создает наблюдаемую асимметрию.
2. Основная масса регионов укладывается в зону до 1500 км от Москвы — рубеж, приблизительно соответствующий протяжённости от столицы до Уральских гор. Регионы, расположенные за пределами этой дистанции, немногочисленны и представлены в основном восточными территориями: Сибирью и Дальним Востоком.
3. Наибольшая плотность точек на графике наблюдается в диапазоне широт 52–58° с.ш. и 0-500 км. до Москвы. Такая концентрация регионов вокруг столицы не является случайной — её истоки уходят в историю феодальной Руси.

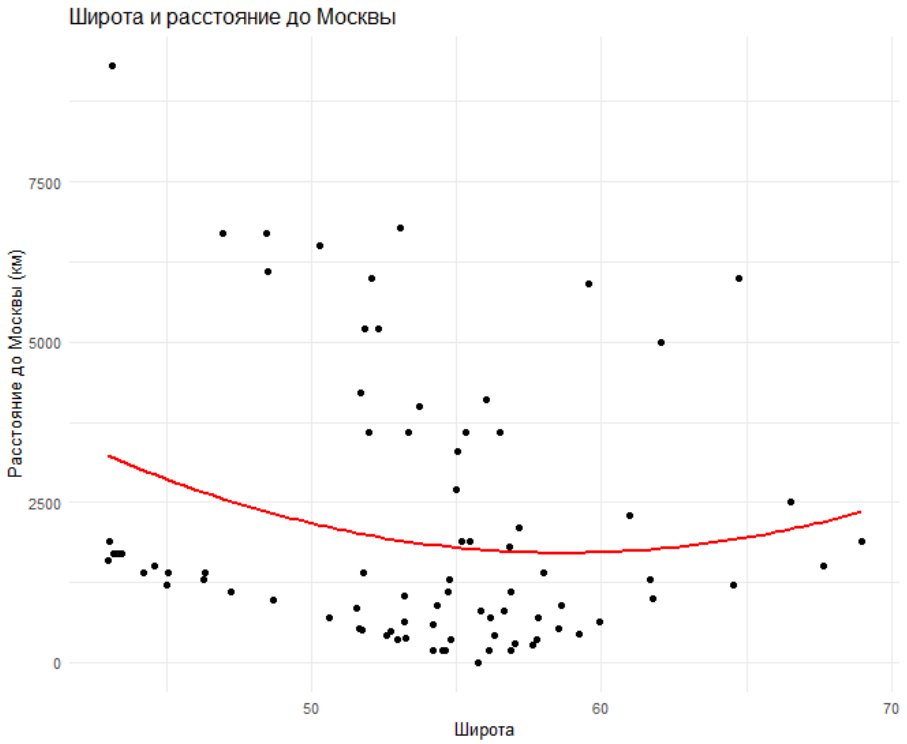

Рис.4. Визуализация географических переменных

График соотношения введенного количества квартир и численности населения подтверждает гипотезу о том, что население выступает основным фактором, определяющим абсолютные масштабы строительства: чем больше людей проживает в регионе, тем больше жилья там возводится. Визуализация выполнена в логарифмических осях, поскольку анализ предполагает исследование логарифмической зависимости между данными переменными. Каждая точка на графике соответствует отдельному наблюдению (паре Год—Регион).
Точки образуют вертикально вытянутые скопления, что свидетельствует о незначительной межгодовой изменчивости численности населения в каждом регионе на фоне устойчивого роста объёмов вводимого жилья. Иными словами, при относительно стабильной демографической структуре регионов строительная активность демонстрирует выраженную положительную динамику, что дополнительно подчёркивает роль не только масштаба населения, но и других факторов, определяющих динамику жилищного строительства.

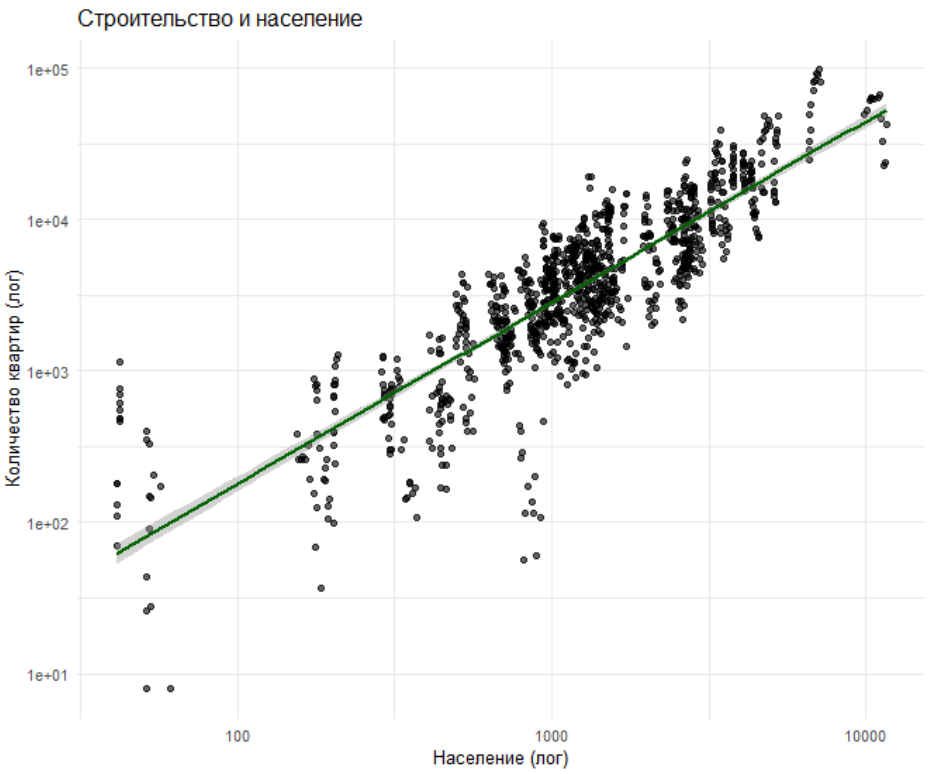

Рис.5. Визуализация отношения строительства и населения

Анализируя доходы населения, логично выявить зависимости с географией и населением, это демонстрируют графики ниже.
На графике соотношения доходов в регионе с его населением (Рис.6.) наблюдается характерная группировка точек в скопления, вытянутые вдоль горизонтальной оси. Аппроксимирующая линия демонстрирует практически горизонтальный тренд, что свидетельствует об отсутствии значимой зависимости между уровнем доходов населения и численностью региона.
Иными словами, в рамках рассматриваемой выборки не прослеживается систематической связи: как крупные, так и небольшие по населению регионы могут демонстрировать как высокие, так и низкие показатели средней заработной платы.

Аппроксимация точек на графике (Рис.7.) образуют положительный тренд: с увеличением широты (движением на север) доходы населения в среднем растут. Данная тенденция объясняется спецификой размещения ресурсодобывающих регионов — Ямало-Ненецкого и Ханты-Мансийского автономных округов, а также ряда северных территорий, где высокая концентрация добывающей промышленности обеспечивает значительно более высокий уровень заработных плат по сравнению с регионами южной и центральной части страны.

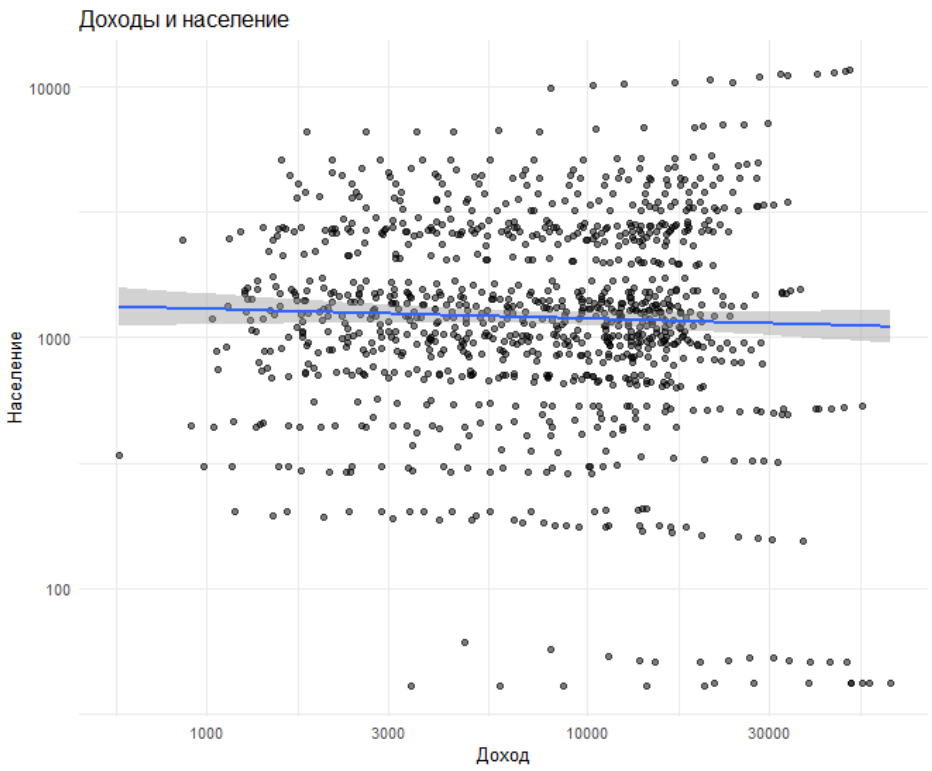

Рис.6. Доходы и численность населения по регионам

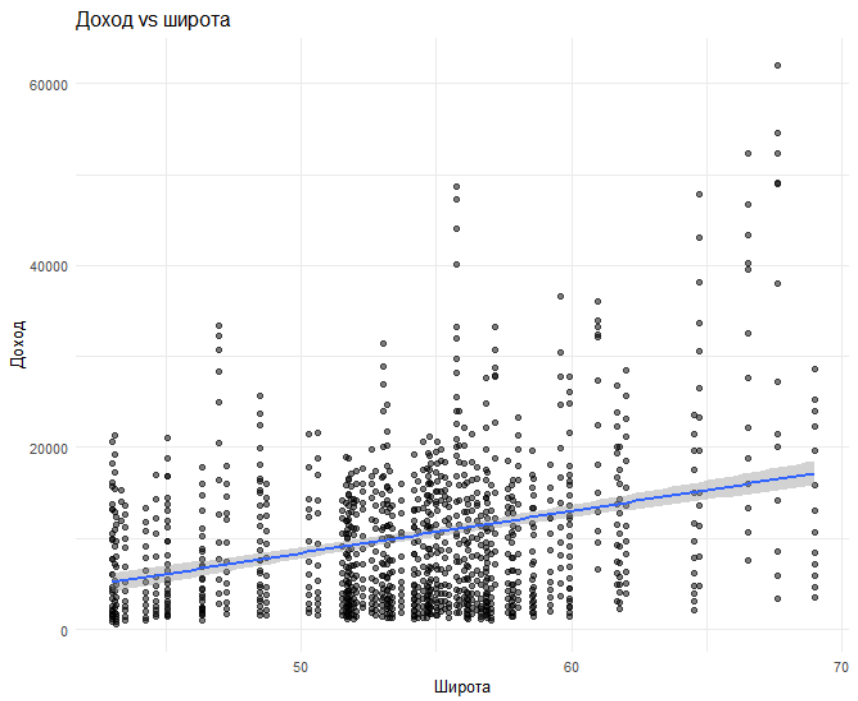

Рис.7. Доходы и широта по регионам

Между удаленностью региона от столицы и масштабами ввода жилья прослеживается устойчивая отрицательная связь: чем дальше регион расположен от Москвы, тем меньше в нём строится квартир. Данная закономерность отражает концентрацию экономической активности, инвестиционных потоков и платежеспособного спроса в центральной части страны.

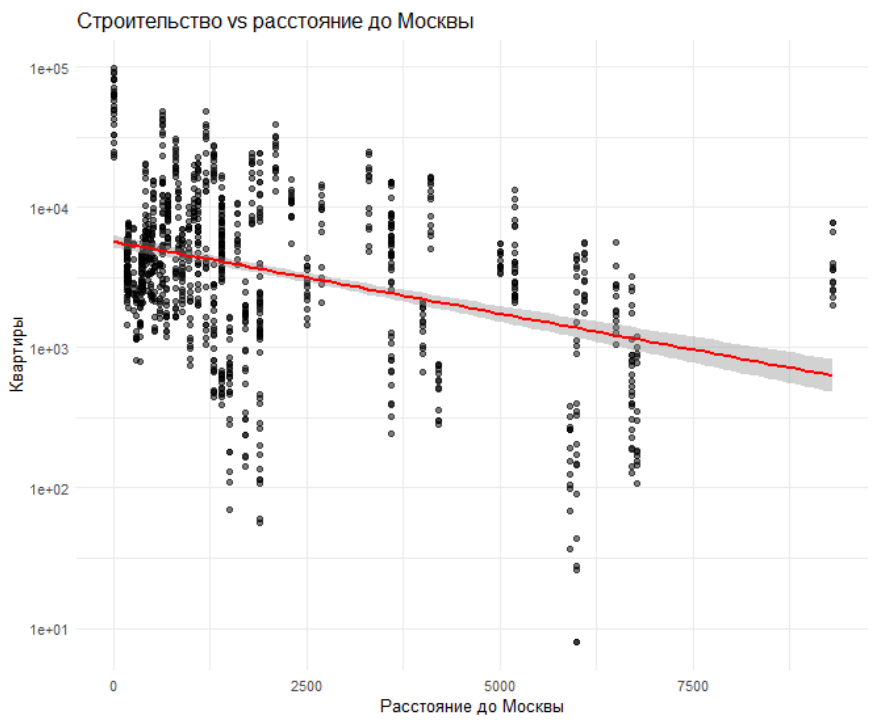

Рис.8. Связь масштабов строительство и удаленности от Москвы

ЭТАП 4: ОБЩАЯ ОКРУЖНАЯ МОДЕЛЬ

Для оценки общероссийской динамики на панельных данных по федеральным округам использовались две спецификации.

ЭТАП 4.1: ОБЩАЯ ОКРУЖНАЯ МОДЕЛЬ (LM)

Pooled регрессия (lm) для оценки вклада как временных, так и пространственных факторов (широта, расстояние до Москвы) в межокружные различия объемов строительства.

$$log(Yit) = \beta 0 + \beta 1 \cdot log(\text{Доходы } it) + \beta 2 \cdot \text{Широта } i + \beta 3 \cdot \text{Расстояние } i + \beta 4 \cdot log(\text{Население } it) + \varepsilon it$$

Анализ параметров регрессии:

- Коэффициент эластичности строительства по доходам составил 0.4 ($p < 0.001$), что подтверждает значимую положительную связь между уровнем заработной платы и объемом жилищного строительства (коэффициент практически полностью сохранился с первого исследования: было 0.406).
- Эластичность по численности населения оказалась близка к единице (0.97, $p < 0.001$). Строительство масштабируется пропорционально численности населения. Это ожидаемый результат — чем больше людей, тем больше потребность в жилье.
- Расстояние до Москвы имеет отрицательный и статистически значимый эффект ($p < 0.001$): удаление на 100 км снижает объем строительства в среднем на 0.83%. Это подтверждает известный феномен: удаленность от центрального рынка (Москвы) снижает инвестиционную привлекательность и активность строительства.
- Географическая широта не оказала значимого влияния, вероятнее всего этот параметр был поглощен предыдущим — расстояние до до Москвы. Несмотря на отрицательный знак (чем севернее, тем меньше строительство), p-value > 0.7 говорит о том, что в данной спецификации широта не дает дополнительной объясняющей способности сверх уже учтенных факторов. Это логично: широта коррелирует с климатом и удаленностью, но после включения расстояния до Москвы ее вклад исчезает.

Итоговая общая окружная lm модель:

$$log(Y) = -1.809 + 0.4031 \cdot log(\text{Доходы}) + 0.9736 \cdot log(\text{Население}) - 0.00008318 \cdot \text{Расстояние}$$

, параметр широты пропущен в связи с его статистической незначимостью.

```
> summary(lm_model_district)

Call:
lm(formula = log(flat_count) ~ log(mean_salary) + log(Population) +
    latitude + distance_to_moscow_km, data = df_all_districts)

Residuals:
     Min       1Q   Median       3Q      Max
-0.50681 -0.09205  0.00024  0.12815  0.40462

Coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)           -1.809e+00  6.155e-01  -2.939  0.00418 **
log(mean_salary)       4.031e-01  2.624e-02  15.365  < 2e-16 ***
log(Population)        9.736e-01  5.373e-02  18.119  < 2e-16 ***
latitude              -1.397e-03  4.263e-03  -0.328  0.74380
distance_to_moscow_km -8.318e-05  1.069e-05  -7.780 1.16e-11 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.1952 on 90 degrees of freedom
Multiple R-squared:  0.9407,    Adjusted R-squared:  0.9381
F-statistic: 357.2 on 4 and 90 DF,  p-value: < 2.2e-16
```

Рис.9. Общая окружная lm модель

Корреляционный анализ выявил ожидаемые и экономически интерпретируемые взаимосвязи. Наиболее сильная положительная связь наблюдается между численностью населения и количеством построенных квартир (r = 0.874), что отражает ключевую роль масштаба территории в формировании объемов строительства: рост населения увеличивает потенциальный спрос, стимулируя предложение жилья. Средняя заработная плата также обнаруживает умеренную положительную корреляцию с зависимой переменной (r = 0.393). Расстояние до Москвы демонстрирует умеренную отрицательную связь (r = -0.582).

Отдельного внимания заслуживает отсутствие корреляции между средним доходом и численностью населения (r = 0.000) — доходы и масштаб территории выступают независимыми факторами, формирующими спрос на жилье.

```
> print(round(cor_matrix_lm, 3))
                     flat_count mean_salary Population latitude distance_to_moscow_km
flat_count                1.000       0.393      0.874    0.427                -0.582
mean_salary               0.393       1.000      0.000    0.040                 0.010
Population                0.874       0.000      1.000    0.439                -0.586
latitude                  0.427       0.040      0.439    1.000                -0.623
distance_to_moscow_km    -0.582       0.010     -0.586   -0.623                 1.000
```

Рис.10. Корреляционная матрица общ. окружной lm модели

Расчет коэффициента инфляции дисперсии (VIF) дал приемлемые значения (< 3) для всех независимых переменных, что значительно ниже критического порога (5-10) и свидетельствует об отсутствии мультиколлинеарности.

Наибольший VIF наблюдается у переменной расстояния до Москвы , что объясняется ее умеренными корреляционными связями с численностью населения и географической широтой: крупные города и южные территории в среднем расположены ближе к столице.

Несмотря на наличие умеренных парных корреляций между некоторыми предикторами, множественная линейная зависимость отсутствует, а оценки

коэффициентов регрессии являются устойчивыми и надежными для содержательной интерпретации.

```
> vif(lm_model_district)
     log(mean_salary)       log(Population)              latitude distance_to_moscow_km
             1.017294              2.103792              1.695745              2.407427
```

Рис.11. Расчет коэффициента инфляции дисперсии

Визуально модель показывает себя отлично, предсказания очень близки к реальным значениям.

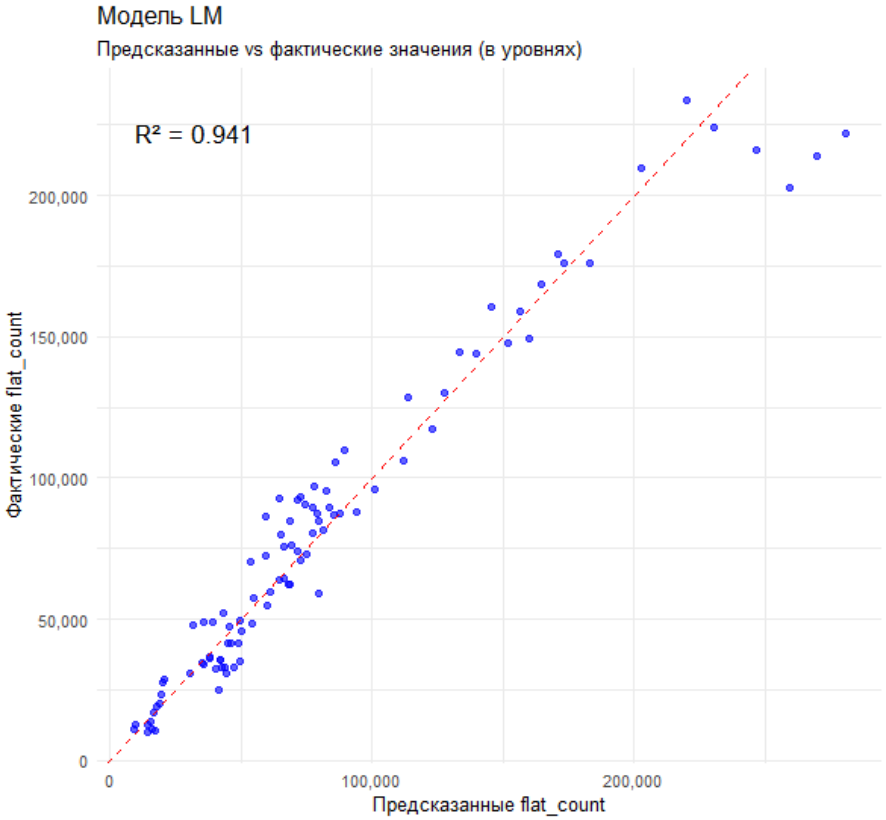

Рис.12. Визуализация общей окружной lm модели

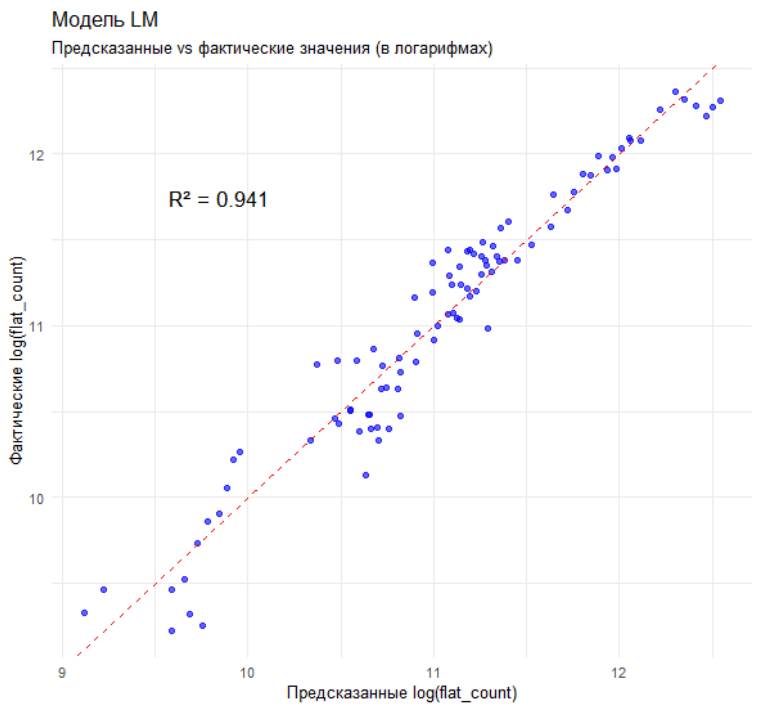

Рис.13. Визуализация общей окружной lm модели (лог. шкала)

Остатки модели имеют равномерное распределение вокруг нулевого мат. ожидания. Наблюдается умеренная гетероскедастичность (небольшое увеличение дисперсии в крайних значениях), однако она не носит ярко выраженного характера. В целом диагностика остатков не выявляет грубых нарушений предположений модели, позволяя считать оценки состоятельными.

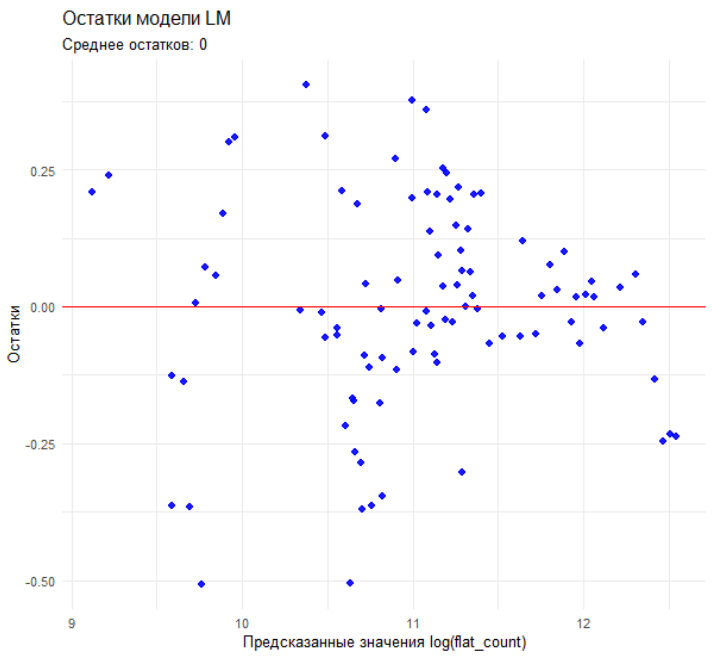

Рис.14. Анализ остатков общей окружной lm модели

На основании анализа остатков, проверки мультиколлинеарности и оценки общей статистической значимости модели можно сделать вывод о состоятельности и корректности построенной регрессионной спецификации. Полученные результаты являются надежными и пригодными для содержательной экономической интерпретации.

```
> summary(lm_model_std)

Call:
lm(formula = log_flat ~ log_salary + log_pop + latitude_s + distance_s,
    data = df_scaled_lm)

Residuals:
     Min       1Q   Median       3Q      Max
-0.64595 -0.11732  0.00031  0.16333  0.51570

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.263e-15  2.552e-02   0.000    1.000
log_salary   3.977e-01  2.588e-02  15.365  < 2e-16 ***
log_pop      6.743e-01  3.722e-02  18.119  < 2e-16 ***
latitude_s  -1.095e-02  3.341e-02  -0.328    0.744
distance_s  -3.098e-01  3.981e-02  -7.780 1.16e-11 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.2488 on 90 degrees of freedom
Multiple R-squared:  0.9407,    Adjusted R-squared:  0.9381
F-statistic: 357.2 on 4 and 90 DF,  p-value: < 2.2e-16
```

Рис.15. Общая окружная модель с стандартизированном виде

Построив уравнение регрессии в стандартизированном масштабе, можно сделать вывод и значимости каждого из коэффициентов регрессии.

Наиболее сильное влияние на объем строительства оказывает численность населения (β = 0.674). Данный результат подтверждает ключевую роль масштаба территории и численности потенциальных потребителей как основного драйвера строительной активности.

Вторым по значимости фактором выступает доход (β = 0.398), отражающий платежеспособный спрос населения.

Третьим значимым фактором является расстояние до Москвы (β = -0.310), которое оказывает умеренное отрицательное влияние. Полученный коэффициент подтверждает наличие агломерационного эффекта столицы: удаленность от Москвы снижает инвестиционную привлекательность и объемы строительства.

Географическая широта (β = -0.011) демонстрирует статистически незначимый эффект (p = 0.744), что указывает на отсутствие самостоятельного влияния этого фактора после учета численности населения и расстояния до Москвы.

$$log(Y) = 0.398 \cdot log(\text{Доходы}) + 0.674 \cdot log(\text{Население}) - 0.31 \cdot \text{Расстояние}$$

ЭТАП 4.2: ОБЩАЯ ОКРУЖНАЯ МОДЕЛЬ (С ФИКС. ЭФФЕКТАМИ)

Модель с фиксированными эффектами (FE), которая фокусируется на внутревременной динамике, исключая влияние неизменных во времени характеристик округов, что дает более чистую оценку эффекта изменения доходов и населения.
Эффект неизменных во времени переменных поглощается индивидуальным фиксированным эффектом αi.
Модель отвечает только на вопрос: *«Как изменение доходов и населения внутри округа влияет на строительство?»*.

$log(Yit) = \alpha i + \beta 1 \cdot log(\text{Доходы } it) + \beta 4 \cdot log(\text{Население } it) + \varepsilon it$, *где* αi *- const для каждого округа*.

Результаты FE-модели демонстрируют принципиально иную картину по сравнению с кросс-секционной регрессией. Средняя заработная плата сохраняет высокую статистическую значимость ($p < 0.001$) с коэффициентом эластичности 0.399, что свидетельствует о наличии устойчивого положительного эффекта роста доходов на объемы строительства внутри округов во времени.
Напротив, численность населения утрачивает статистическую значимость ($p = 0.955$). Данный результат имеет важное экономическое содержание: население определяет межокружные различия в уровнях строительства (что подтверждается высокой значимостью в кросс-секционной модели), но не оказывает значимого влияния на внутреокружную динамику в рассматриваемом временном горизонте.
Иными словами, регионы с изначально высокой численностью населения демонстрируют большие объемы строительства, однако изменения численности населения внутри региона не приводят к пропорциональным изменениям строительной активности.

Фиксированные эффекты отражают базовый уровень строительства для каждого округа, в то время как эффект повышения дохода имеет общий коэффициент для всей страны, а эффект населения минимален и статистически незначим. Так, например, ЦФО строит в ~7 раз больше квартир, чем ДВФО, даже если зарплата и население меняются одинаково. Это чистый «окружной эффект» (инфраструктура, политика, спрос, география и т.д.).

Округ	Множитель	log-уровень
Центральный федер ...	3892	8.267
Приволжский федер ...	3134	8.050
Южный федеральный ...	1745	7.465
Сибирский федерал ...	1666	7.418
Северо-Западный ф ...	1386	7.234
Уральский федерал ...	1182	7.075
Северо-Кавказский ...	618	6.426
Дальневосточный ф ...	367	5.904

Рис.16. Фиксированные эффекты в логарифмической шкале

```
> summary(model2_fe)
Oneway (individual) effect Within Model

Call:
plm(formula = log(flat_count) ~ log(mean_salary) + log(Population) +
    latitude + distance_to_moscow_km, data = df_all_districts,
    model = "within", index = c("Регион", "Год"))

Unbalanced Panel: n = 8, T = 4-13, N = 95

Residuals:
      Min.    1st Qu.     Median    3rd Qu.       Max.
-0.3010827 -0.1010556  0.0018492  0.0973028  0.2955714

Coefficients:
                Estimate Std. Error t-value Pr(>|t|)
log(mean_salary) 0.398505   0.021985 18.1262   <2e-16 ***
log(Population)  0.010945   0.191327  0.0572   0.9545
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Total Sum of Squares:    9.9601
Residual Sum of Squares: 1.8558
R-Squared:      0.81368
Adj. R-Squared: 0.79395
F-statistic: 185.603 on 2 and 85 DF, p-value: < 2.22e-16
```

Рис.17. Общая окружная FE модель

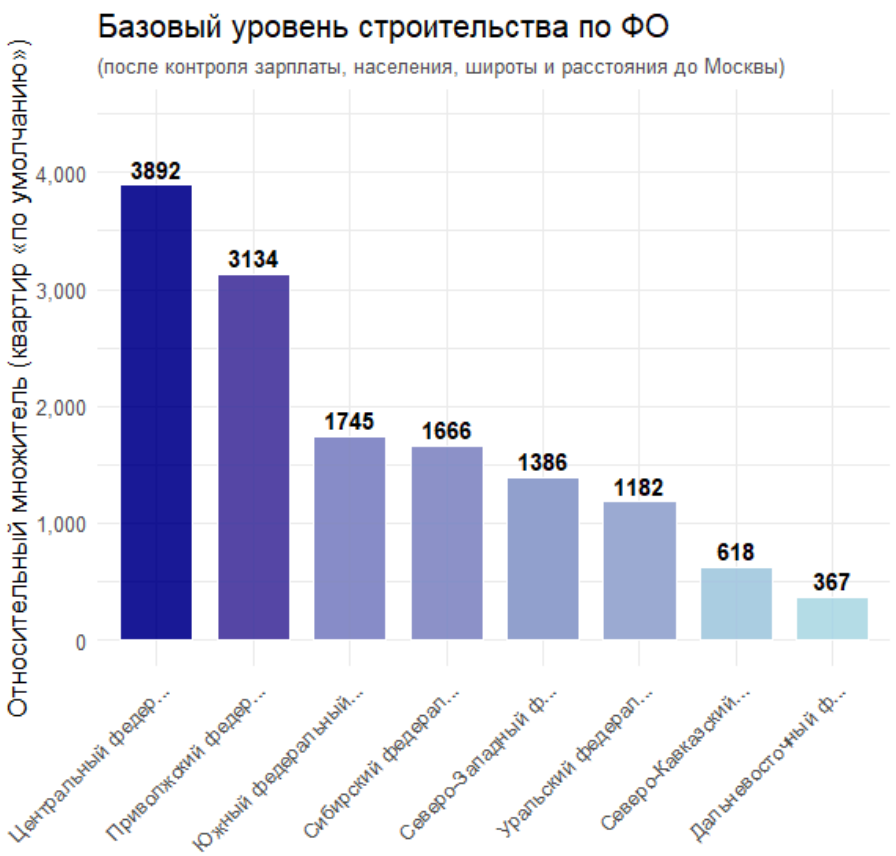

Рис.18. Анализ фиксированных эффектов общей окружной модели

Итоговая общая окружная plm модель (фикс. эффекты):
$log(Yit) = \alpha i + 0.398 \cdot log(\text{Доходы } it) + 0.01 \cdot log(\text{Население } it) + \varepsilon it$, *где* αi *- const для каждого округа*.

Стимулирование строительства через рост доходов населения является более эффективным инструментом в кратко- и среднесрочной перспективе, чем ориентация на демографические изменения. Последние определяют скорее "потолок" потенциального объема строительства в регионе, но не его динамику. Это подтверждается уравнением регрессии в стандартизированном виде:

$log(Yit) = \alpha i + 0.393 \cdot log(\text{Доходы } it) + 0.007 \cdot log(\text{Население } it) + \varepsilon it$, *где* αi *- const для каждого округа*.

Стоит отметить, что стандартизация переменных в модели с фиксированными эффектами не изменяет значения t-статистик и уровней значимости, поскольку она представляет собой линейное преобразование, сохраняющее структуру внутригрупповой вариации.

Остатки модели имеют равномерное распределение вокруг нулевого мат. ожидания. Наблюдается умеренная гетероскедастичность, однако она не носит ярко выраженного характера. В целом диагностика остатков не выявляет грубых нарушений предположений модели, позволяя считать оценки состоятельными.

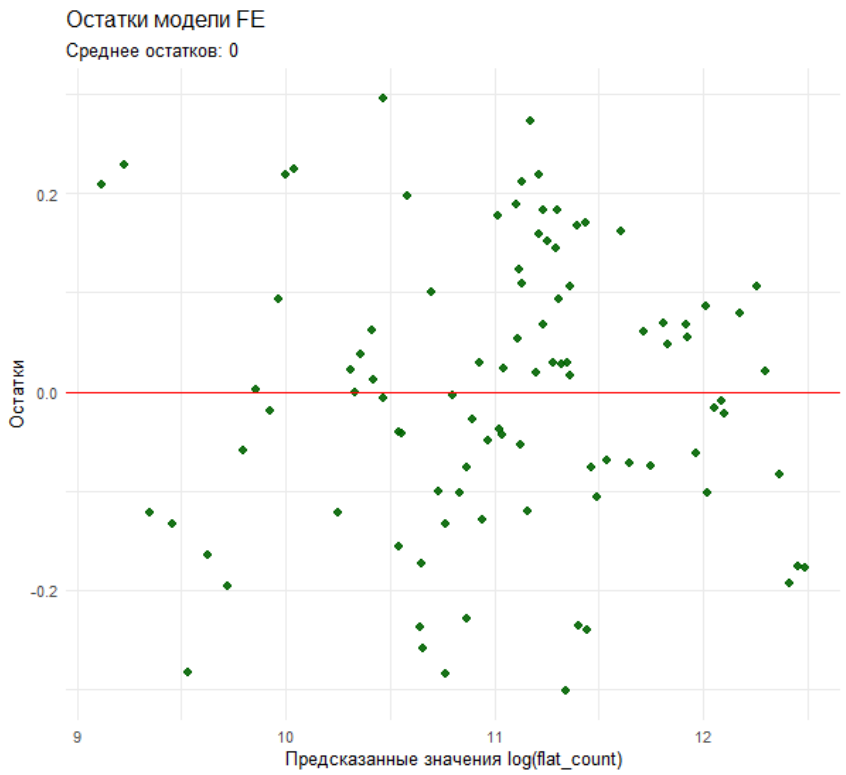

Рис.19. Анализ остатков общей окружной FE модели

ЭТАП 4.3: ИТОГ ПО ОБЩИМ ОКРУЖНЫМ МОДЕЛЯМ

Исходные данные для построения представленных моделей представляют собой панельную структуру, агрегированную до уровня федеральных округов (8 округов за 13 лет).
Высокое качество (R^2 = 0.94 и R^2 = 0.81) и статистическая значимость ключевых коэффициентов позволяют использовать данные модели для оценки общих закономерностей на национальном уровне, а также для сравнительного анализа тенденций между федеральными округами.
Вместе с тем, ввиду эффекта агрегирования и существенной гетерогенности регионов внутри каждого округа, обобщение полученных результатов на уровень отдельных регионов некорректно. Прогнозирование объемов строительства на региональном уровне на основе окружных моделей нецелесообразно; для этих целей требуется построение моделей на региональных данных по субъектам Российской Федерации.

Модели показали важные экономические выводы:

1. Основной драйвер строительства для каждого из округов - доходы населения. Коэффициент эластичности ≈ 0.4, полученный в исследовании №1, подтвердился.
2. Население определяет “базовый” уровень строительства, но его влияние на динамику масштаба строительства оказалось статистически незначимым.
3. Факторы расстояния до Москвы и географической широты коррелированы, и второй размывается на фоне первого, но экономически они ведут себя ожидаемо и имеют отрицательные коэффициенты.

Для сравнение моделей используем среднюю MAPE, полученную для каждого региона.

	LM модель	PLM модель
ЦФО	10.25	10.01
СЗФО	11.15	10.07
ЮФО	18.85	14.89
СФО	13.92	15.46
УрФО	9.25	9.11
ПФО	6.78	7.50
СКФО (с 2009 г.)	48.91	6.2
ДВФО	23.33	15.05
Итого:	17.81	11.04

Табл.1. Сравнение общих окружных моделей

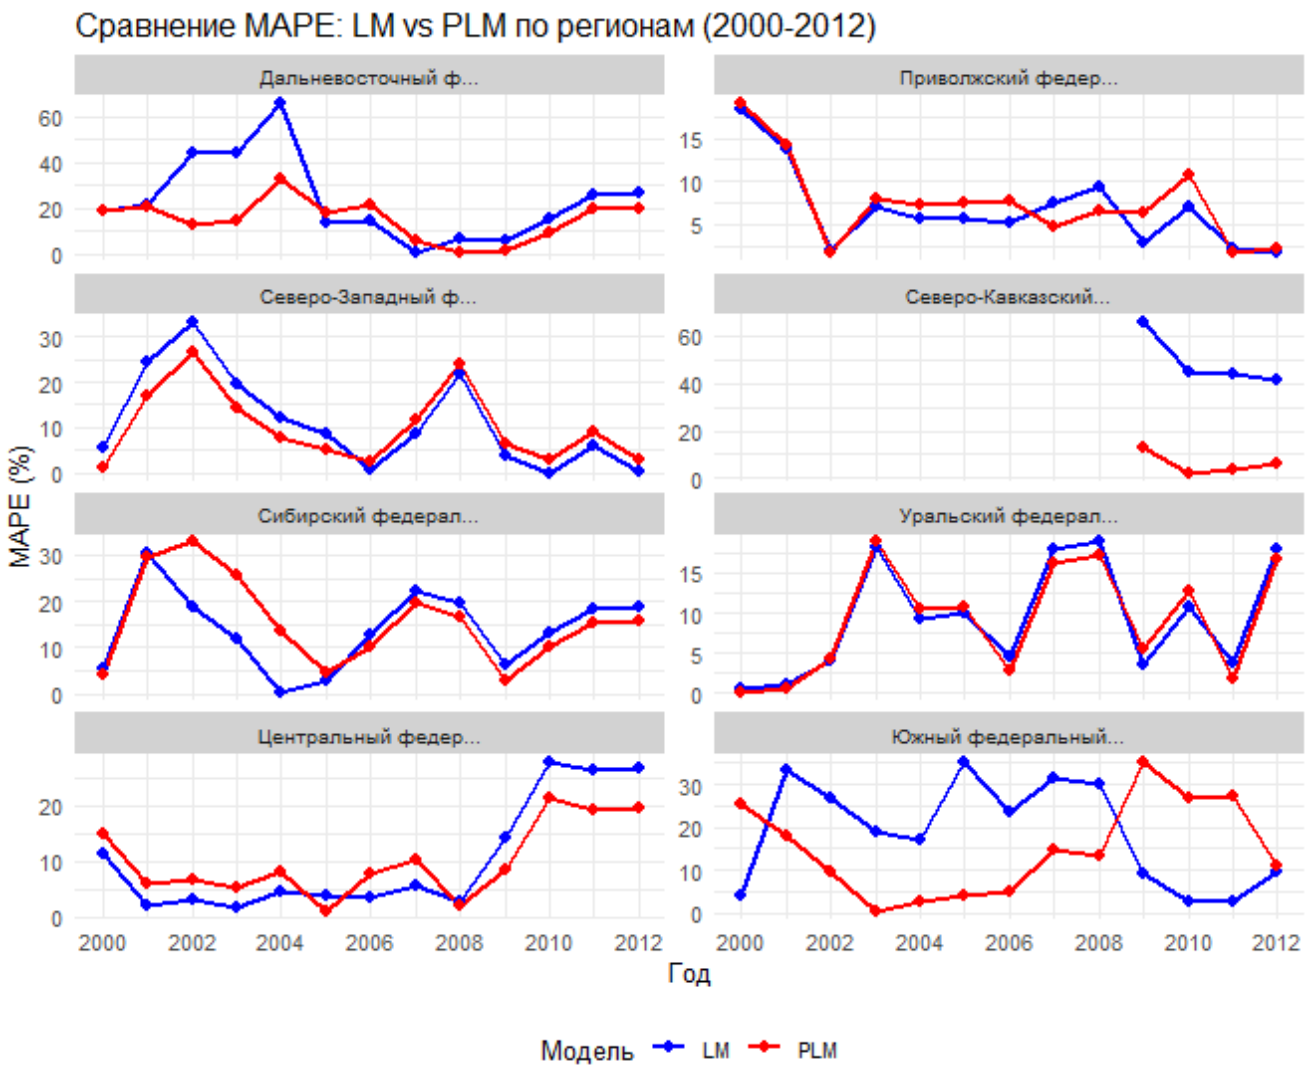

Рис.20. Сравнение общих окружных моделей

Обе модели показали себя достаточно хорошо, большие ошибки имеет только LM модель для СКФО, но это можно объяснить минимальным набором данных для этого округа. Итоговая оценка в полтора раза лучше у модели с фиксированными эффектами, будем считать её основной.

Сравнивая полученную PLM модель с итоговой pooled PLM моделью из исследования №1, можно отметить значительное улучшение результата, полученная модель стабильнее для составления прогнозов по Федеральным округам (MAPE упал с 21% до 11%, а R^2 поднялся с 0.51 до 0.81).

Следующий этап анализа - построение регрессионных моделей для каждого из округов и нахождение закономерностей, которые смогут подтвердить промежуточные выводы.

ЭТАП 5: ЧАСТНЫЕ ОКРУЖНЫЕ МОДЕЛИ

Данные из общей выборки были разделены на 8 подвыборок, каждая из которых содержит записи о регионах одного из федеральных округов.
Для каждого округа по аналогии с общей окружной будет построено две модели: lm и plm.
Подробный анализ каждой из моделей аналогично общим окружным моделям представлен не будет, чтобы не утопить работу с бесконечных графиках и выводах программы, но каждая из моделей была проверена:

1. Анализ остатков, график.
2. Анализ предсказанных настоящих и значений.
3. Корреляционная матрица и проверка явления мультиколлинеарности.
4. Коэффициенты эластичности и уравнение регрессии в станд. масштабе.

ЭТАП 5.1: ЦФО

	LM модель	PLM модель
MAPE	30.79	17.23
Значимые коэффициенты	Доход, население, широта	Доход, население
R^2	0.85	0.54
R^2adj	0.84	0.50
Остатки	Умеренная гетерогенность, нулевое мат.ожидание	Умеренная гетерогенность, нулевое мат.ожидание

Табл.2. Сравнение моделей для ЦФО

$log(Yit) = \alpha i + 0.259 \cdot log(\text{Доходы } it) - 1.48 \cdot log(\text{Население } it) + \varepsilon it,$ *где* αi *- const для каждого региона ЦФО*.

$$log(Yit) = 0.328 \cdot log(\text{Доходы } it) + 1.56 \cdot log(\text{Население } it) - 0.095 \cdot \text{Широта} + \varepsilon it$$

Аналогично общей окружной модели PLM показывает лучший результат (ошибка ниже на 13%), при этом низкий R^2 не должен смущать: FE модель объясняет 54% изменений внутри регионов во времени, в то время как R^2 LM модели выше, так как её коэффициенты объясняют межрегиональную вариацию, от этого растет коэф. детерминации (объясняющая способность).
Отметим также то, что у LM модели коэффициент перед расстоянием до Москвы оказался статистически незначим, объясняется это очень просто — регионы ЦФО все сконцентрированы вокруг Москвы и расстояние у всех нулевое, либо околонулевое.

Также можем отметить деталь, которую уловила LM модель: чем севернее регион, тем меньше там строят, это влияние минимально, но статистически значимо.

Наиболее интересная деталь итогового результата — отрицательный коэффициент перед населением в FE модели. Это объясняется тем, что ЦФО — самый «насыщенный» округ России. В регионах вроде Москвы, МО, Воронежа, Твери уже мало свободной земли, высокие цены, жесткое регулирование. Когда население растет, строительство не поспевает. Это классический эффект «насыщения» в густонаселенных районах.

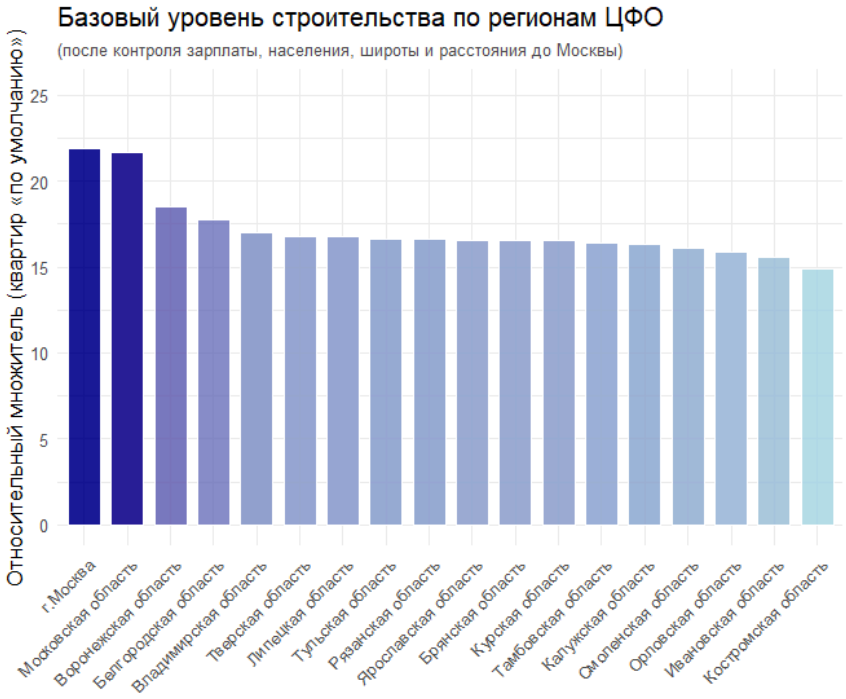

Рис.21. Фиксированные эффекты модели ЦФО (логарифмы)

Анализ фиксированных эффектов подтверждает сильную неоднородность регионов внутри ЦФО: Москва и Московская область имеют огромные фиксированные эффекты (“базовый уровень”).

У PLM модели наблюдается существенное снижение ошибки в сравнении со своим предшественником из исследования №1 (17% против 21%).

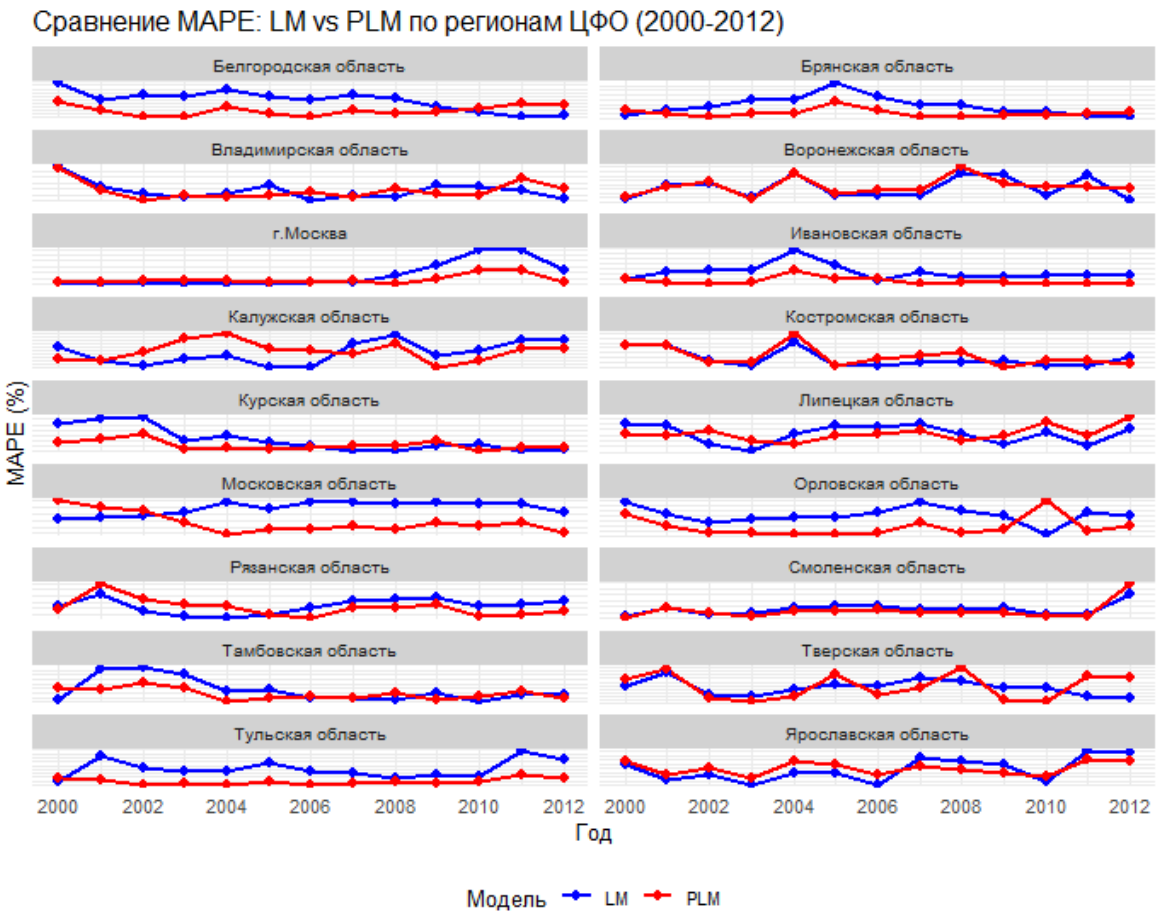

Рис.22. Сравнение моделей ЦФО

ЭТАП 5.2: ПФО

	LM модель	PLM модель
MAPE	22.76	13.19
Значимые коэффициенты	Свободный член, доход, население, расстояние	Доход, население
R^2	0.83	0.76
R^2adj	0.82	0.74
Остатки	Нулевое мат.ожидание, очень слабая гетерогенность	Нулевое мат.ожидание, очень слабая гетерогенность

Табл.3. Сравнение моделей для ПФО

$log(Yit) = \alpha i + 0.284 \cdot log(\text{Доходы } it) - 2.99 \cdot log(\text{Население } it) + \varepsilon it,$ *где* αi - *const для каждого региона ПФО.*

$$log(Yit) = -2.25 + 0.385 \cdot log(\text{Доходы } it) + 1.02 \cdot log(\text{Население } it) - 0.0002 \cdot \text{Расстояние} + \varepsilon it$$

Эластичность строительства по доходам выросла в сравнении с ЦФО, это говорит о том, что в ПФО доходы населения вносят больший вклад в масштабы строительства.
А вот эластичность по населению упала, вероятнее всего это связано с экономической особенностью Приволжья, которое является промышленным центром страны, что влечет ограниченность земельных ресурсов в промышленных агломерациях. Приволжье исторически плотно заселено, что также влечет снижение строительства в относительном плане. Это означает, что внутри региона во времени строительство не успевает за ростом населения.

Также статистическую значимость в LM модели потеряла широта, а вот расстояние до Москвы наоборот имеет значимость, связано это с тем, что расстояние до столицы имеет значение в масштабах страны, влияя на инвестиционную привлекательность, но в рамках ЦФО это влияние пропадало.

Обе модели показывают себя лучше, чем их конкуренты, созданные для ЦФО. Это говорит о том, что прогнозирование в ПФО более стабильно, а средняя ошибка меньше. Показатель MAPE достигает 13% е FE модели, что считается отличным показателем для экономической модели. Объясняющая способность больше почти на 20%, это следствие того, что в ПФО масштабы строительства намного лучше объясняются численностью населения и доходами.

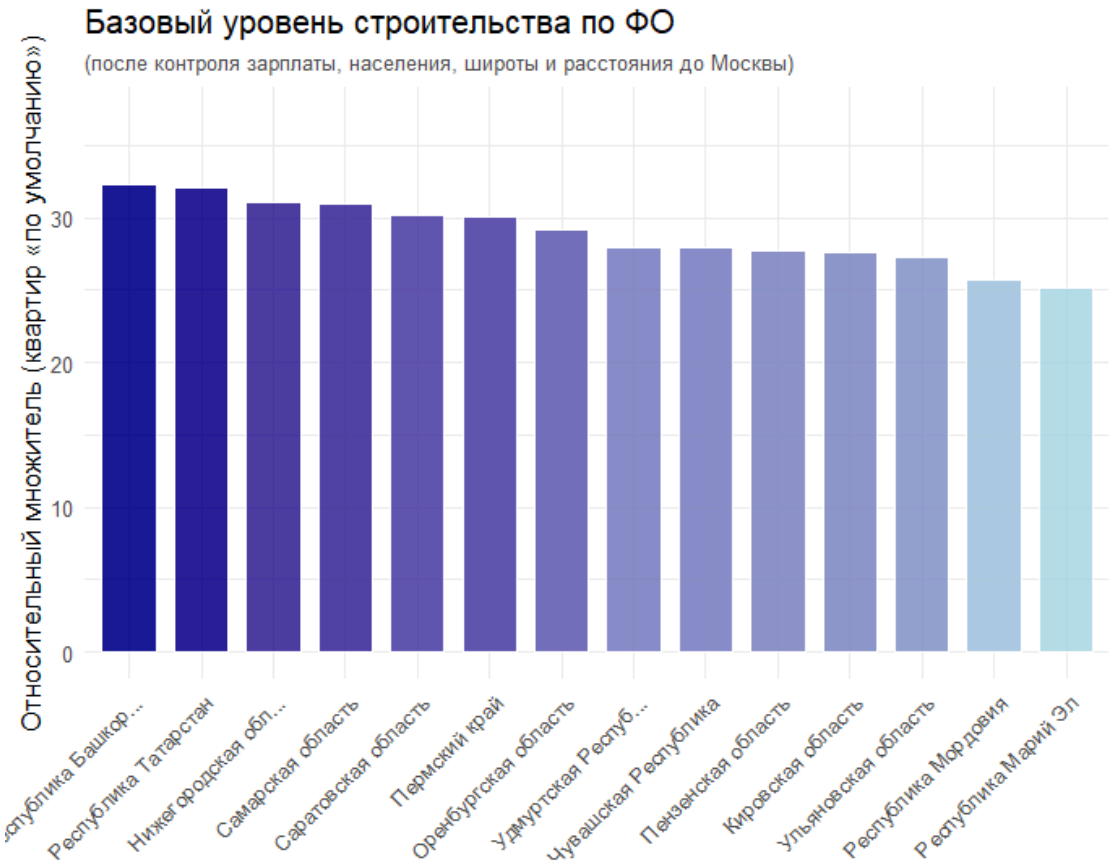

Рис.23. Фиксированные эффекты ПФО

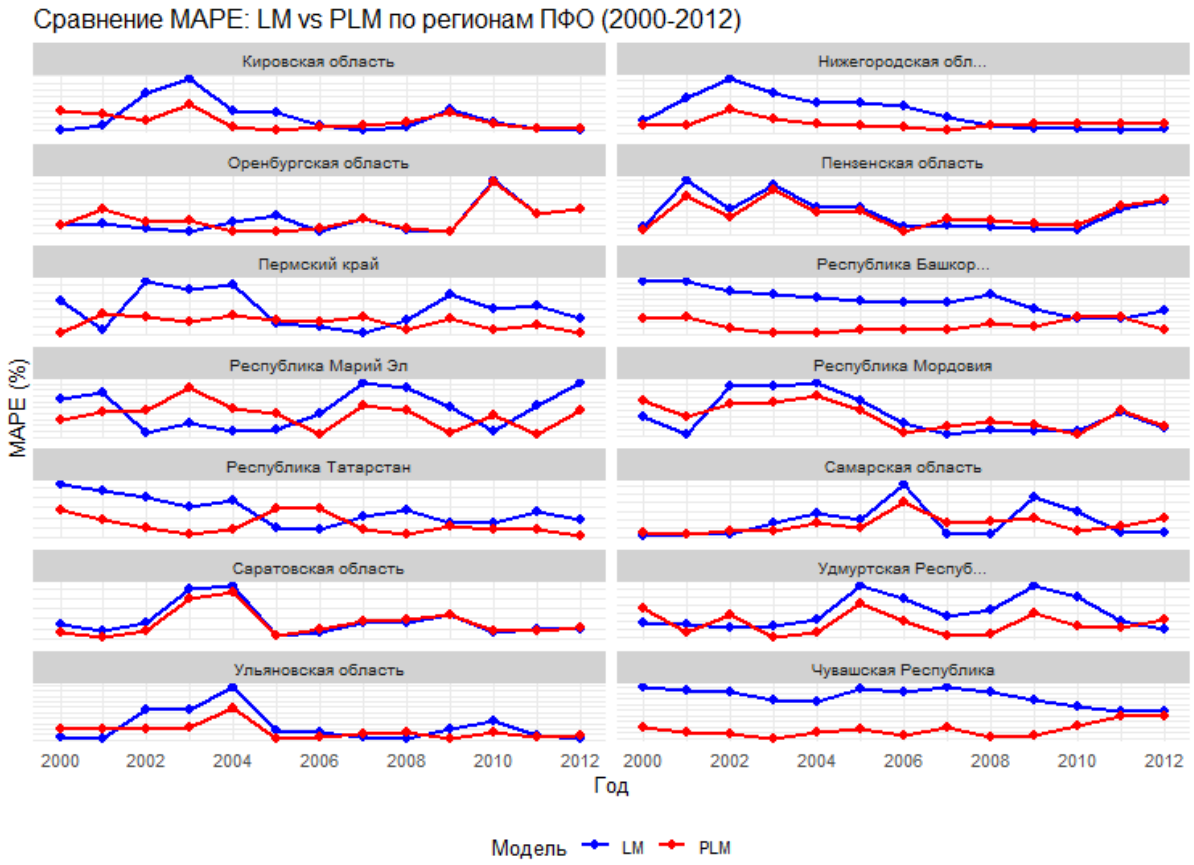

Рис.24. Сравнение моделей ПФО

ЭТАП 5.3: СЗФО

	LM модель	PLM модель
MAPE	58.41	25.13
Значимые коэффициенты	СВободный член + все 4 регрессора	Доход, население
R^2	0.81	0.57
R^2adj	0.81	0.53
Остатки	Нулевое мат.ожидание, очень слабая гетерогенность	Нулевое мат.ожидание, очень слабая гетерогенность в наблюдениях с низким строительством

Табл.4. Сравнение моделей для ПФО

$log(Yit) = \alpha i + 0.614 \cdot log(\text{Доходы } it) + 3.624 \cdot log(\text{Население } it) + \varepsilon it$, *где* αi *- const для каждого региона СЗФО*.

$log(Yit) = 4.409 + 0.653 \cdot log(\text{Дох. } it) + 0.616 \cdot log(\text{Нас. } it) - 0.001 \cdot \text{Расст.} - 0.08 \cdot \text{Шир.} + \varepsilon it$

Первое, что бросается в глаза — положительный коэффициент у населения в FE модели, СЗФО — это округ, где строительство успевает за ростом населения и даже опережает его. Причиной этому видится активный рост Санкт-Петербурга и его агломерации. В отличие от ЦФО и ПФО, где наблюдается эффект насыщения, СЗФО демонстрирует эффект масштабирования: рост населения является драйвером жилищного строительства, а не ограничивающим фактором.
Очень выросла эластичность по доходам, строительный сектор очень чувствителен к платежеспособности населения.

В LM модели отметим, что впервые значимы оказались все коэффициенты, в СЗФО на строительство статистически значимое влияние оказывает как расстояние до Москвы, так и широта, знаки при коэффициентах демонстрируют отрицательную связь между этими переменными и вводом нового жилья, что логично с экономической точки зрения.

FE модель демонстрирует приемлемые, но не лучшие показатели: объясняющая способность на уровне ЦФО, но ошибка на 8% выше. А вот LM модель показывает ужасную ошибку в 58%.
Были рассмотрены другие комбинации зависимостей для PLM модели, но ни одна из не оказалась лучше, чем исходная логарифмическая.

Рассмотреть подробно именно этот округ было необходимо, т.к. в дальнейшем нужно будет построить прогноз для республики Карелия. Но рассмотрение СЗФО позволило наглядно показать, что единой логики развития жилищного строительства в России нет. Если ЦФО и ПФО сталкиваются с ограничениями роста (земля, плотность), то СЗФО сохраняет потенциал для экстенсивного развития за счет территориальных резервов и динамичного развития Санкт-Петербургской агломерации.

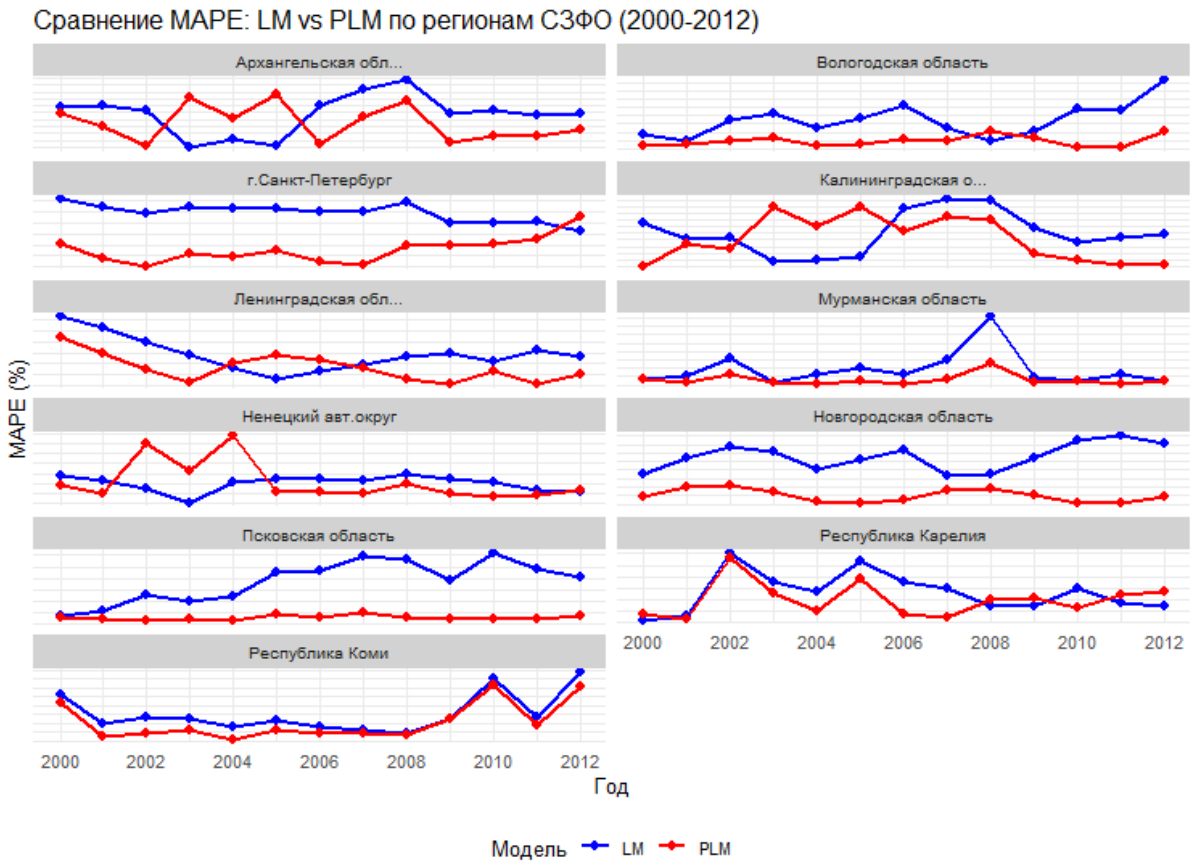

Рис.25. Сравнение моделей СЗФО

ЭТАП 5.4: ПРОЧИЕ ОКРУГА

	R^2(R^2adj) LM	MAPE LM	R^2(R^2adj) LM	MAPE PLM
ЮФО	0.93 (0.93)	25.99	0.56 (0.52)	18.01
УрФО	0.90 (0.90)	20.13	0.74 (0.71)	14.72
СФО	0.93 (0.93)	24.10	0.75 (0.73)	16.89
ДВФО	0.79 (0.78)	66.70	0.41 (0.36)	48.95
СКФО	0.86 (0.85)	29.4	0.40 (0.33)	21.21

Табл.5. Прочие округа

Остальные округа подробно разобраны не будут, для них приведена сводная таблица, отражающая основные метрики: объясняющая способность и средняя ошибка.

Модели для УрФО, ЮФО и СФО показали хорошие результаты, превзойдя точность модели из исследования №1, модель СКФО имеет аналогичные показатели, а огорчила только модель ДВФО со средней ошибкой в почти 50%.
Средняя ошибка всех моделей составила 21%, но убирая ДВФО, получаем оценку в **18.05%**, что уже можно считать значимым улучшением.
Все модели статистически значимы и пригодны для составления экономических прогнозов.

ЭТАП 6: ПРОГНОЗ ДЛЯ РЕСПУБЛИКИ КАРЕЛИЯ

В прогнозе для республики Карелия за 2007 год значительно точнее оказалась модель PLM, в среднем для этого региона за 13 лет наблюдений она также оказалась точнее своего конкурента и обогнала модель из исследования №1: 19% против 25% и 21% соответственно.

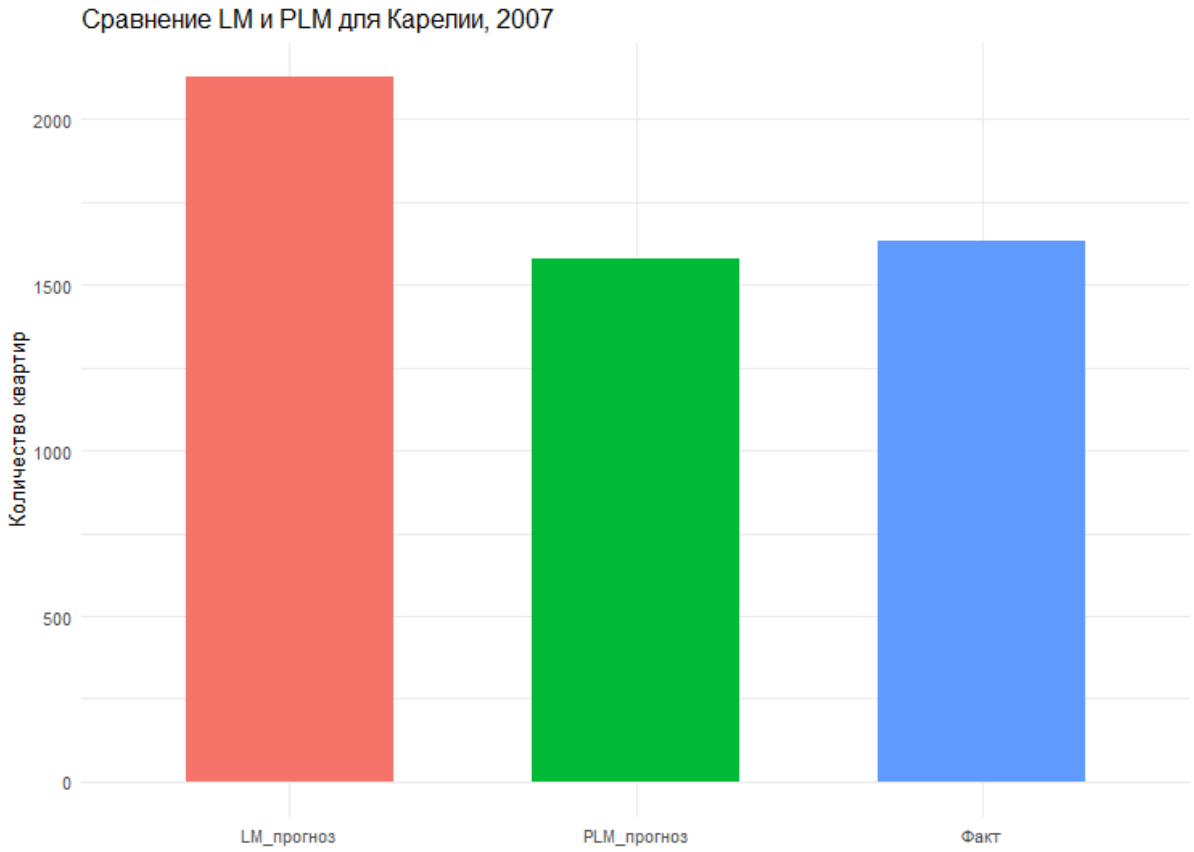

Рис.26. Прогноз для Карелии (2007)

```
> print(comparison)
              Регион  Год Факт LM_прогноз PLM_прогноз Ошибка_LM Ошибка_PLM
1 Республика Карелия 2007 1634   2126.324     1577.66  492.3236  -56.34044
```

Рис.27. Прогноз для Карелии (2007): вывод программы

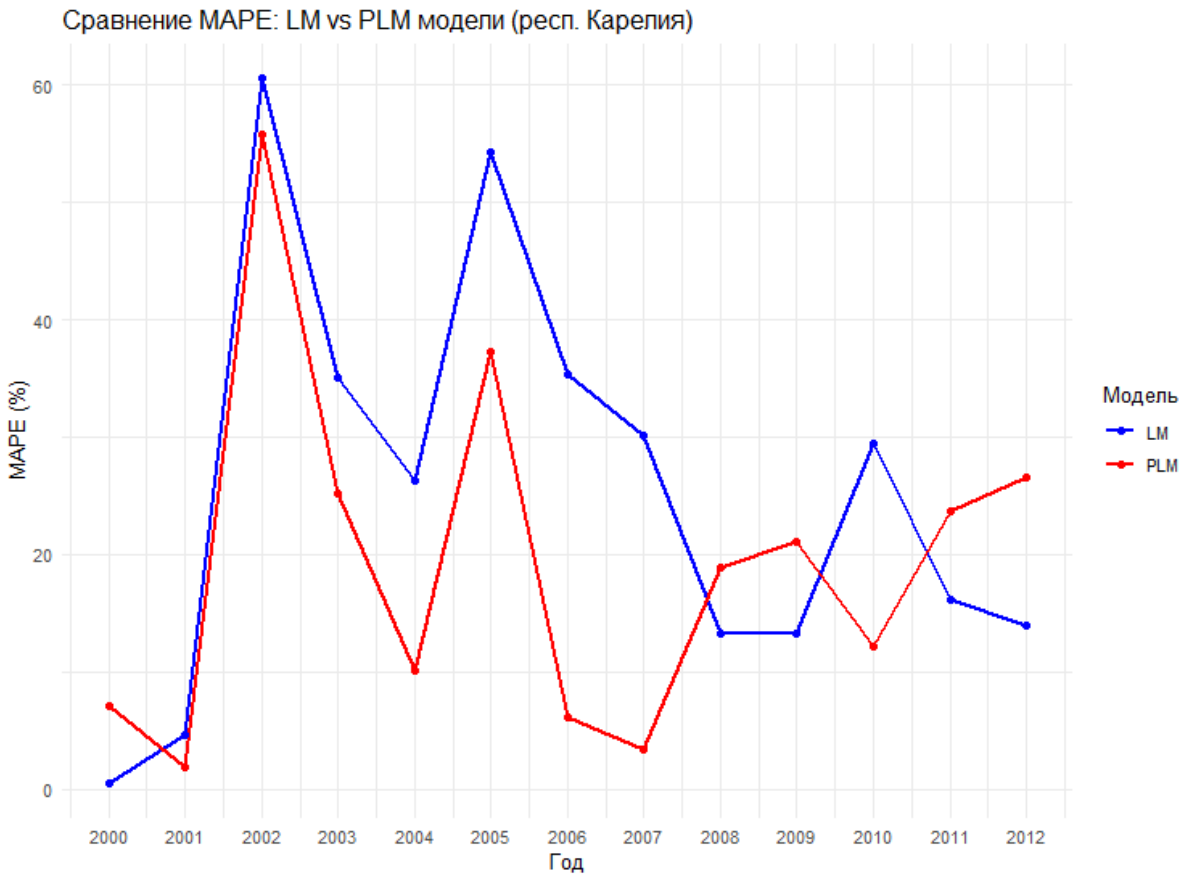

Рис.28. Сравнение моделей СЗФО для прогноза по Карелии

Согласно оценке, выполненной на основе PLM модели, прогнозное количество введённых квартир в Республике Карелия в 2020 году составило 2860 единиц. Фактические данные о вводе жилья в натуральном выражении (квартирах) в открытых источниках отсутствуют, однако известен совокупный объём введённой жилой площади — 294 тыс. кв. метров. При средней площади квартиры, характерной для регионального рынка в тот период (ориентировочно 65–75 кв. м), это соответствует примерно 4000 введённых квартир.

Таким образом, модельный прогноз оказался ниже фактического показателя, что может объясняться как структурными особенностями ввода (доля индивидуального жилищного строительства, которая в модели могла быть учтена не в полной мере), так и действием не включенных в спецификацию факторов, включая меры государственной поддержки строительной отрасли в 2020 году.

Но в целом оценку можно считать состоятельной: ошибка в 28% вполне допустима для экономической модели.

ЗАКЛЮЧЕНИЕ

В рамках данного исследования была проведена комплексная оценка факторов, определяющих объемы жилищного строительства в регионах Российской Федерации, с использованием как кросс-секционных, так и панельных регрессионных моделей. В отличие от модели из исследования №1 (парная логарифмическая регрессия с единственным фактором дохода), в текущей работе была реализована многомерная спецификация, учитывающая демографические и географические характеристики регионов.

Ключевым результатом исследования стало подтверждение устойчивости и экономической интерпретируемости зависимости между доходами населения и объемами строительства. Во всех рассмотренных моделях коэффициент эластичности по доходам стабильно находился на уровне около 0.4, что означает: рост доходов на 1% сопровождается увеличением объемов строительства примерно на 0.4%. Это свидетельствует о том, что платежеспособный спрос является основным драйвером развития строительного сектора, причем данный вывод полностью согласуется с результатами исследования №1 и подтверждает его устойчивость при расширении модели.

Включение дополнительных факторов позволило существенно углубить экономическую интерпретацию. Было показано, что численность населения играет принципиально разную роль в зависимости от уровня анализа. В кросс-секционном разрезе (между регионами и округами) население выступает ключевым фактором, определяющим базовый масштаб строительства: более крупные регионы строят больше жилья. Однако в динамике (внутри регионов во времени) влияние населения оказалось статистически незначимым. Это означает, что демографические изменения носят инерционный характер и не являются краткосрочным драйвером роста строительства, формируя скорее «потолок» спроса, чем его динамику.

Географические факторы также продемонстрировали значимое экономическое содержание. Расстояние до Москвы оказалось устойчиво значимым и отрицательно влияющим на объемы строительства, отражая пространственную концентрацию экономической активности, инвестиций и спроса в центральной части страны. В то же время географическая широта утратила значимость при включении расстояния, что указывает на наличие мультиколлинеарности и подтверждает, что именно экономико-географическая близость к центру, а не климатические условия, является определяющим фактором.

Сравнение различных модельных спецификаций показало, что модели с фиксированными эффектами (PLM) обладают наилучшей прогностической способностью. Они позволяют корректно учитывать ненаблюдаемые постоянные различия между регионами (инфраструктура, институциональная среда, исторические особенности) и дают более точные прогнозы (снижение MAPE с ~21% в исследовании №1 до ~11% на уровне округов). Это подтверждает важность учета панельной структуры данных при анализе региональной экономики.

Анализ частных моделей по федеральным округам выявил существенную неоднородность механизмов формирования жилищного строительства в России. В ряде округов (ЦФО, ПФО) наблюдается эффект насыщения: рост населения не сопровождается соответствующим ростом строительства из-за ограниченности земельных ресурсов и высокой плотности застройки. В других (например, СЗФО) сохраняется потенциал экстенсивного роста, где увеличение населения стимулирует строительство. Данный результат подчеркивает невозможность применения единой модели развития для всей страны и необходимость учета региональной специфики при формировании экономической политики.

Построение прогноза для Республики Карелия продемонстрировало практическую применимость разработанных моделей. Несмотря на наличие отклонения от фактических значений, полученные оценки находятся в допустимых пределах точности для эконометрических моделей и превосходят результаты базовой модели из исследования №1. Это подтверждает, что учет дополнительных факторов и использование панельных методов действительно повышают качество прогнозирования.

В целом результаты исследования позволяют сделать важный прикладной вывод: стимулирование жилищного строительства в кратко- и среднесрочной перспективе должно быть ориентировано прежде всего на рост доходов населения и повышение платежеспособного спроса, тогда как демографическая политика оказывает более долгосрочное и косвенное влияние. Пространственные различия (в первую очередь близость к экономическим центрам) также должны учитываться при разработке региональных программ развития.

Таким образом, проведенное исследование не только подтвердило выводы, полученные в рамках модели из исследования №1, но и существенно расширило их, выявив сложную многофакторную природу жилищного строительства и продемонстрировав преимущества использования панельных эконометрических методов для анализа региональных данных.

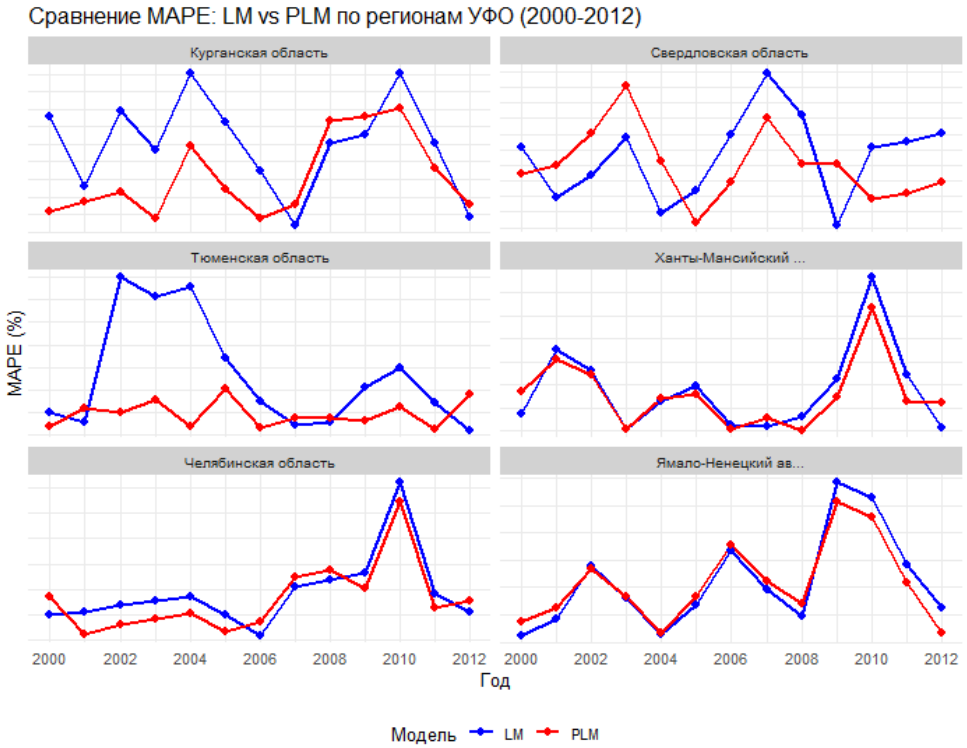

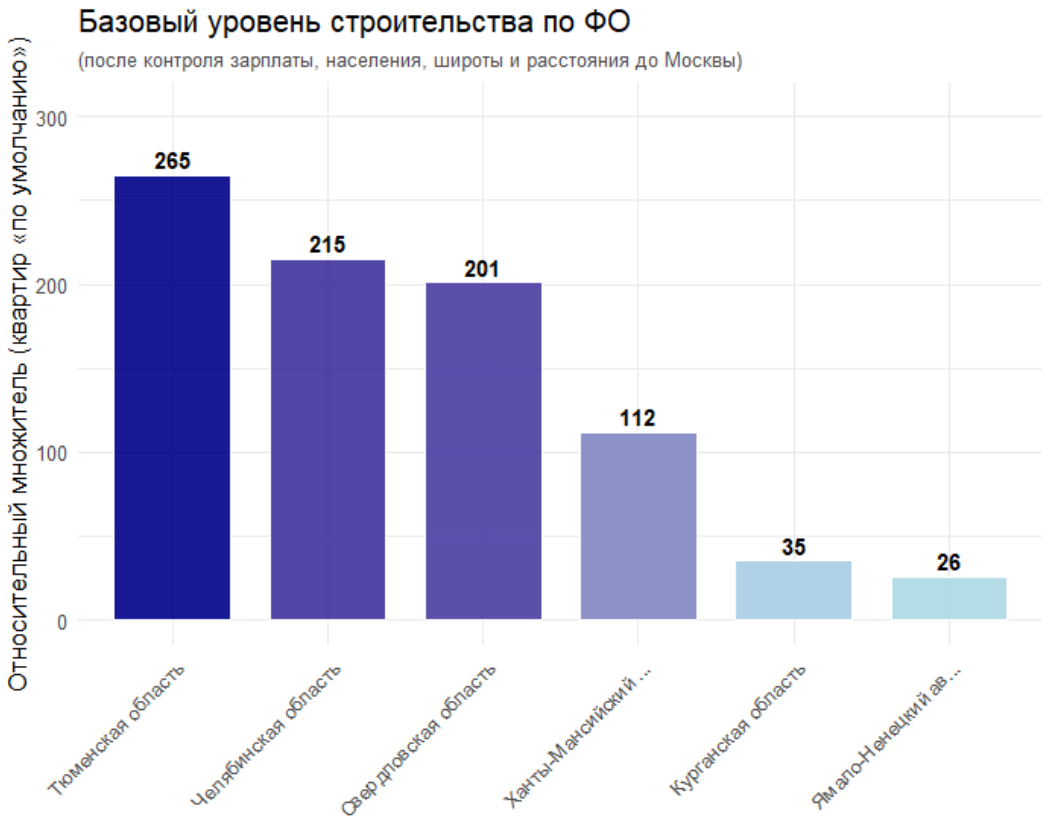

Приложение 1. УФО

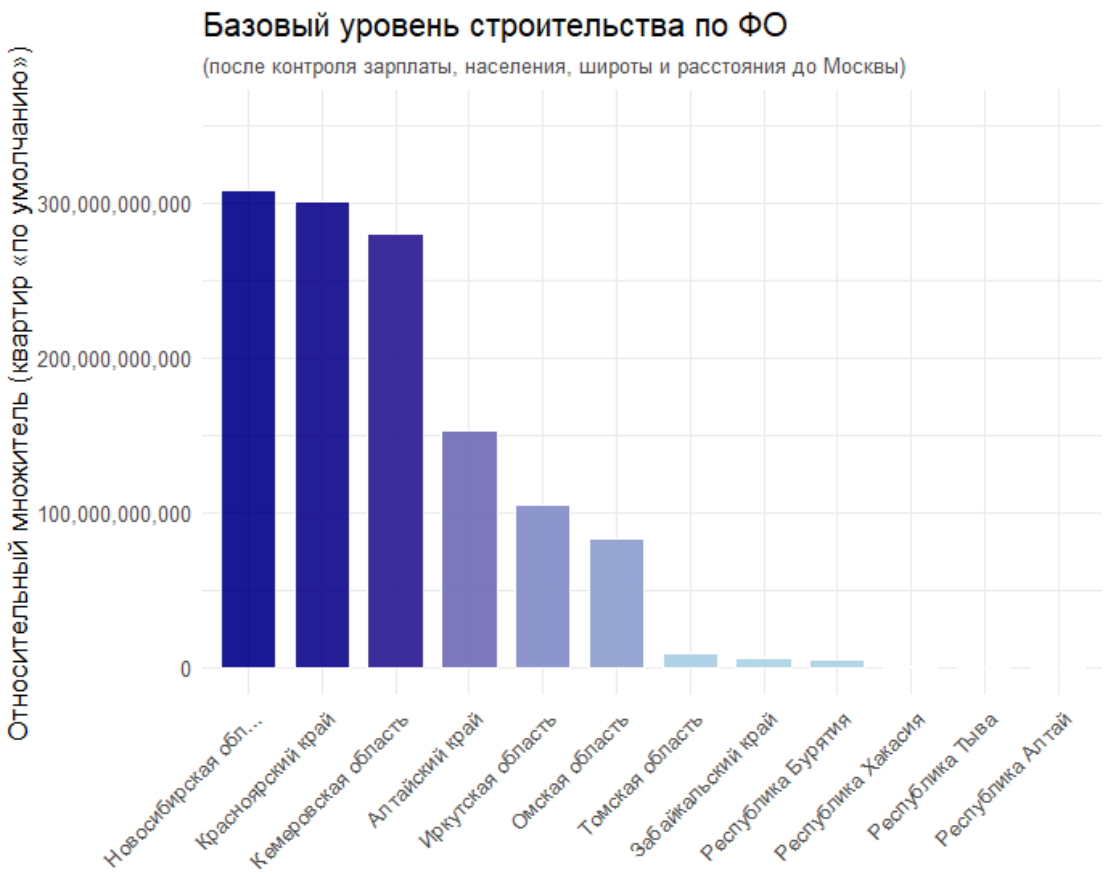

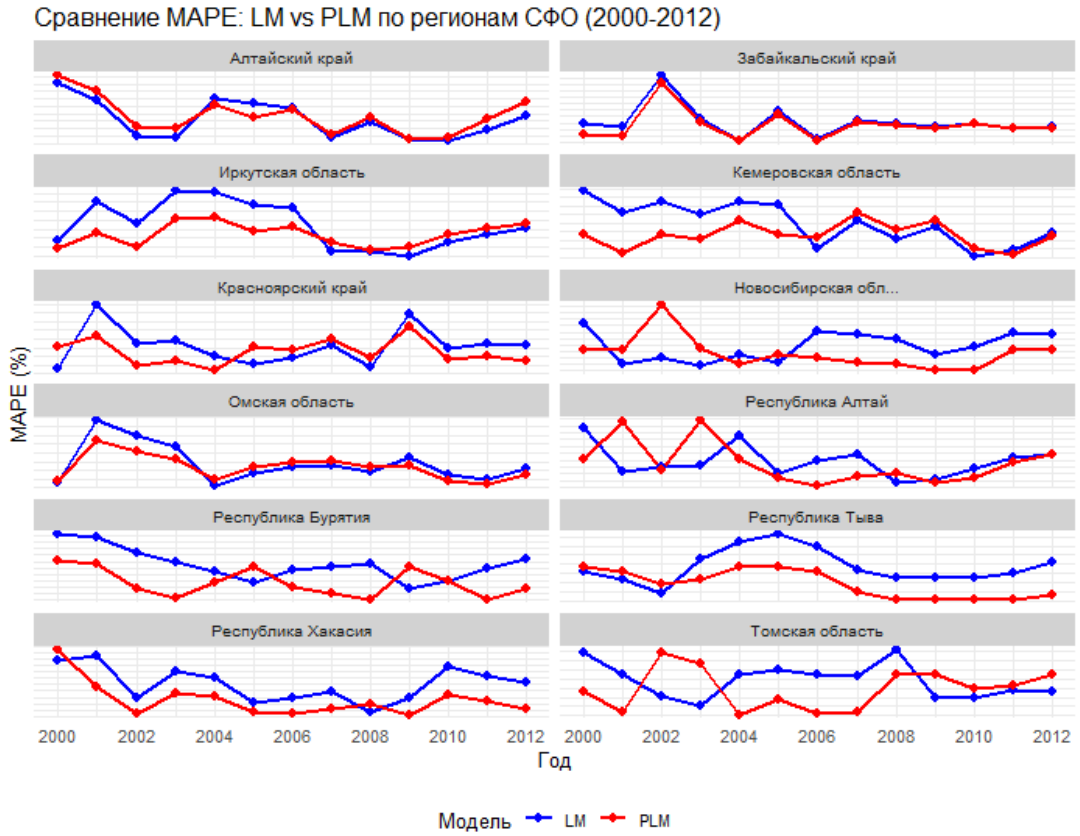

Приложение 2. СФО

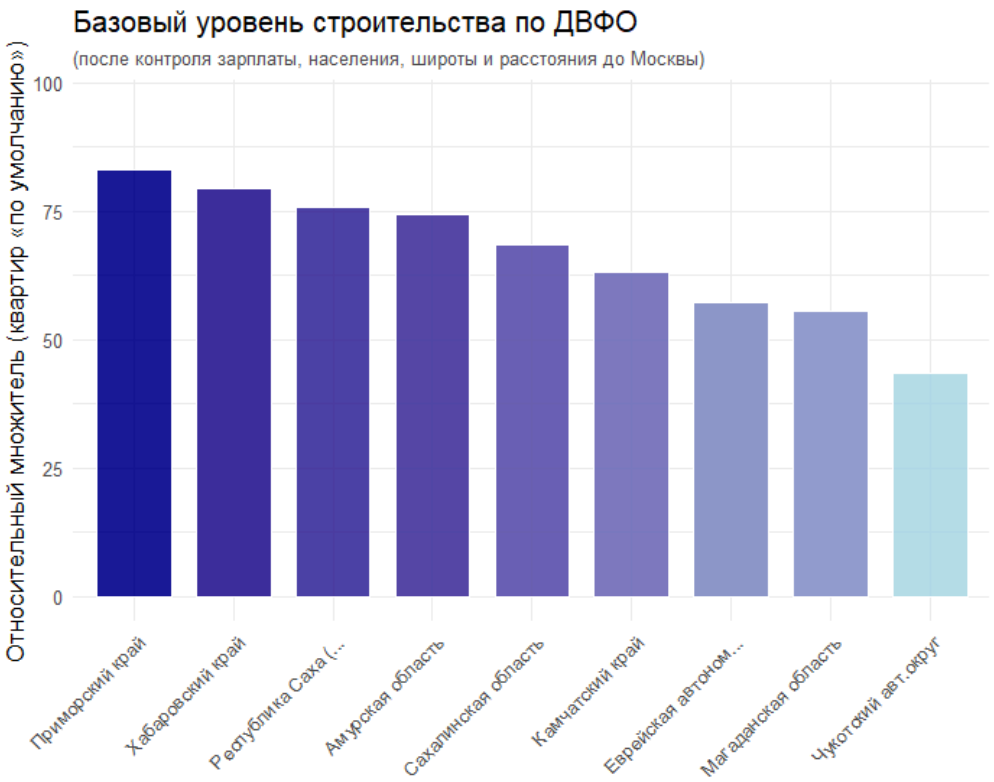

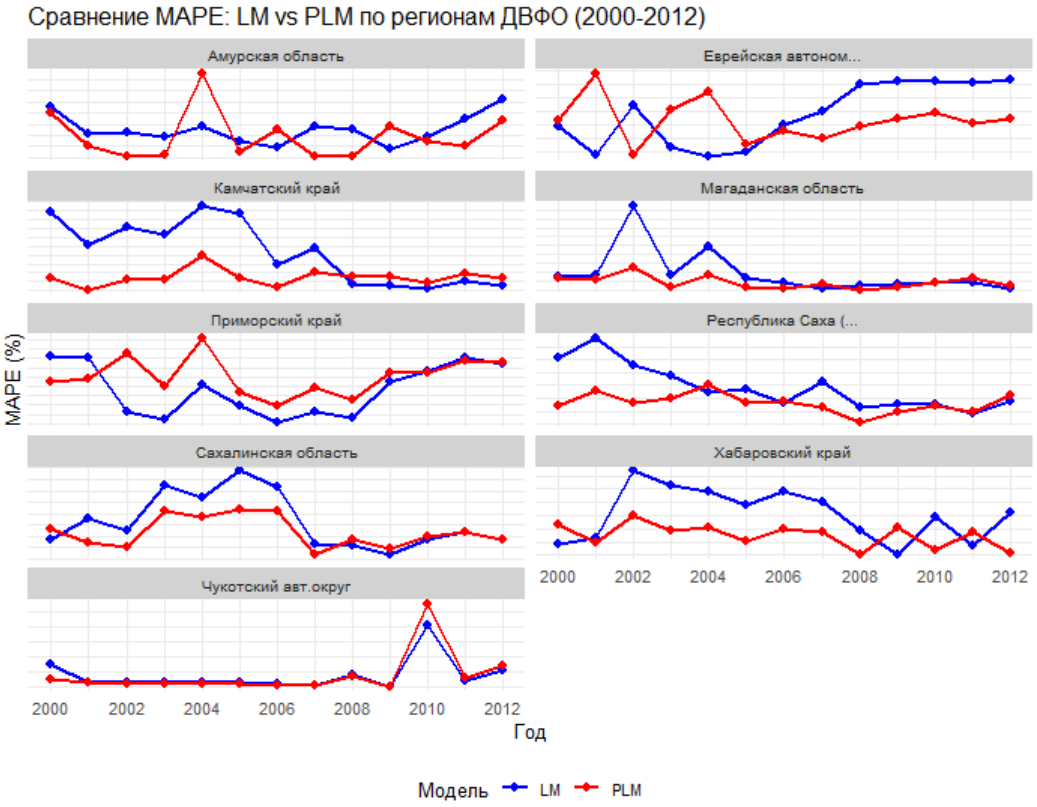

Приложение 3. ДВФО

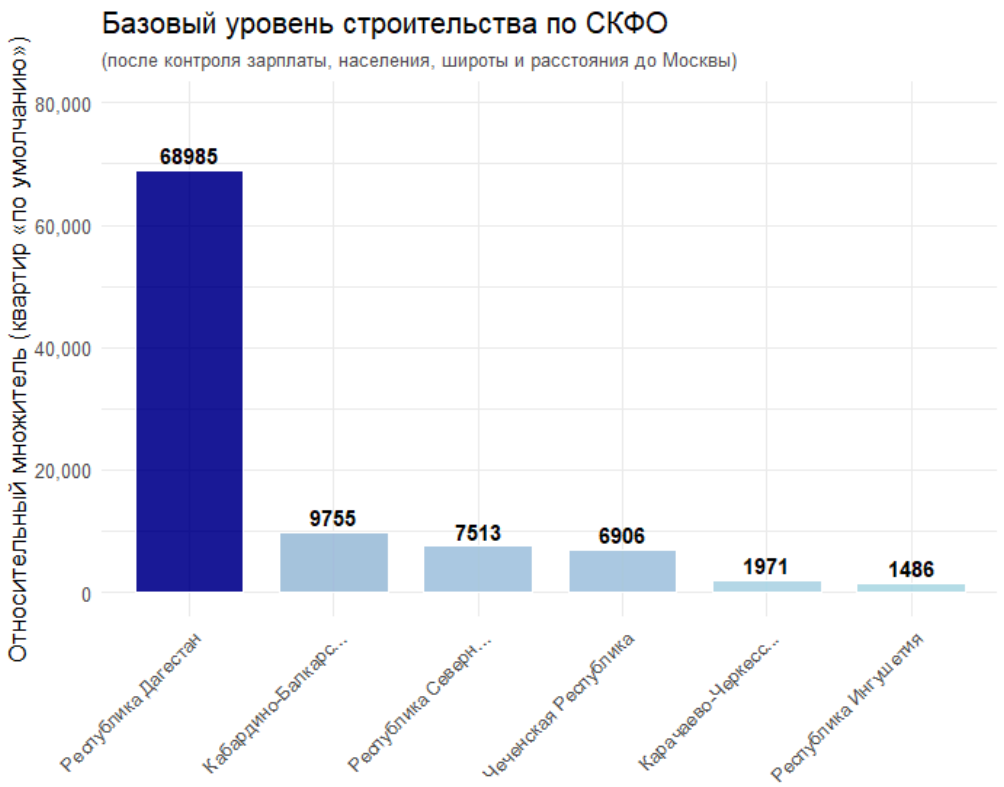

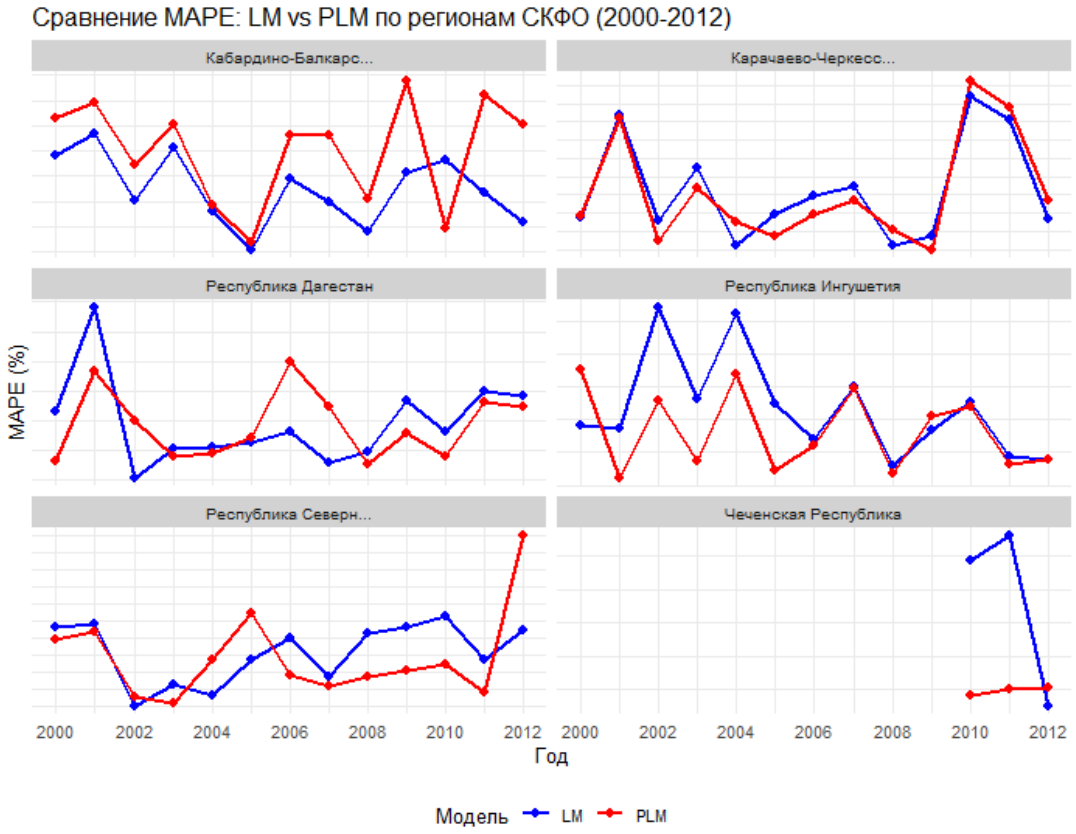

Приложение 4. СКФО